

基于深度学习方法进行病害检测和结构健康监测研究综述

何至立

(东南大学土木工程学院, 江苏 南京, 211189)

摘要: 随着计算机软硬件设备的发展、大数据分析技术和深度学习理论的进步, 深度学习技术在各行各业受了广泛关注并产生了颠覆性的影响。将深度学习技术引入结构健康监测和病害检测等传统的土木工程任务也引起了越来越多的研究人员的关注。首先系统地介绍了机器学习、深度学习、结构监测和病害检测的内涵和研究进展。然后全面地回顾了深度学习的发展和基于深度学习的土木工程领域内有影响力的, 最新的文献, 对当前的研究进行了分类。从一维数据、二维数据、三维数据和智能化检测设备等角度对研究进行了科学的分类。此外, 还对目前主要的研究热点进行了归纳, 包括结构响应预测、损伤定位、结构性能评估、健康监测数据清洗、结构表观病害自动检测和分割、智慧施工、结构三维重建、点云数据分割和智能检测设备等等。最后, 对领域的未来发展进行了展望。本文旨在为本领域研究人员提供借鉴和相关参考资料, 推动相关领域的进一步发展。

关键词: 机器学习; 深度学习; 病害检测; 结构健康监测

Damage Detection and Structural Health Monitoring Using Deep Learning: A State-of-the-Art Review

HE Zhili

(School of Civil Engineering, Southeast University, Nanjing 211189, Jiangsu, China)

Abstract : With the development of computer software and hardware equipment, the progress of big data analysis technology and deep learning theory, deep learning technology has been widely concerned in all walks of life and has a subversive impact. Introducing deep learning techniques into traditional civil engineering tasks such as structural health monitoring and damage detection has also attracted more and more researchers' attention. Firstly, the connotation and research progress of machine learning, deep learning, structure monitoring and damage detection are systematically introduced. Then the development process of deep learning and the latest influential literature in the field of civil engineering based on deep learning are reviewed and the current research is classified. This paper classifies the research from the perspectives of one-dimensional data, two-dimensional data, three-dimensional data and intelligent detection equipment. Additionally, the main research hotspots are summarized, including structural response prediction, damage location, structural performance evaluation, health monitoring data cleaning, automatic detection and segmentation of structural apparent diseases, intelligent construction, 3D reconstruction of structures, point cloud data segmentation and intelligent detection equipment. Finally, the future development of the field is prospected. This paper aims to provide reference for researchers in this field and promote the further development of related fields.

Key words: Machine learning; Deep learning; Damage detection; Structural health monitoring

收稿日期: 没投稿. 完成于 2020 年 7 月.

基金项目: 无基金资助.

作者简介: 何至立, (1998-), 男, 硕士研究生, E-mail: hzl@seu.edu.cn.

1 引言

机器学习（Machine learning, ML）是一门多领域交叉学科，涉及概率论、统计学、逼近论、凸分析、算法复杂度理论等多门学科。ML 专门研究计算机怎样模拟或实现人类的学习行为，以获取新的知识或技能，重新组织已有的知识结构使之不断改善自身的性能。ML 是人工智能的核心，是使计算机具有智能的根本途径^[1]，它使得计算机能够在没有明确编程的情况下学习。自上世纪提出迄今，ML 已经在科学和工程、金融和人文等等发挥了巨大作用，影响了人们生活的方方面面。

ML 算法最常见的划分是分为有监督学习和无监督学习两类^[2]。后续又发展出弱监督学习，这是

一种介于有监督学习和无监督学习之间的理论。有监督学习利用标记数据集的先验知识来学习一个最接近数据中输入和标记输出之间关系的函数。而无监督学习的目的是推断一组没有目标标签的数据点的自然结构。相比于有监督学习，无监督学习的优点是不需要先验知识，避免了复杂的数据集建立过程；但是，其缺点是因为先验知识不足，很难学习到有效的结果。提高无监督学习的学习效果也是目前研究的热点之一。根据数据特征（离散或连续）和任务目标，有监督学习又可以进一步细分为分类和回归，而无监督学习包括聚类和降维^[3]。图 1 总结了两种类型的 ML 和一些比较常用和经典的 ML 算法。在下一节，将会介绍机器学习中最新被提出的算法。

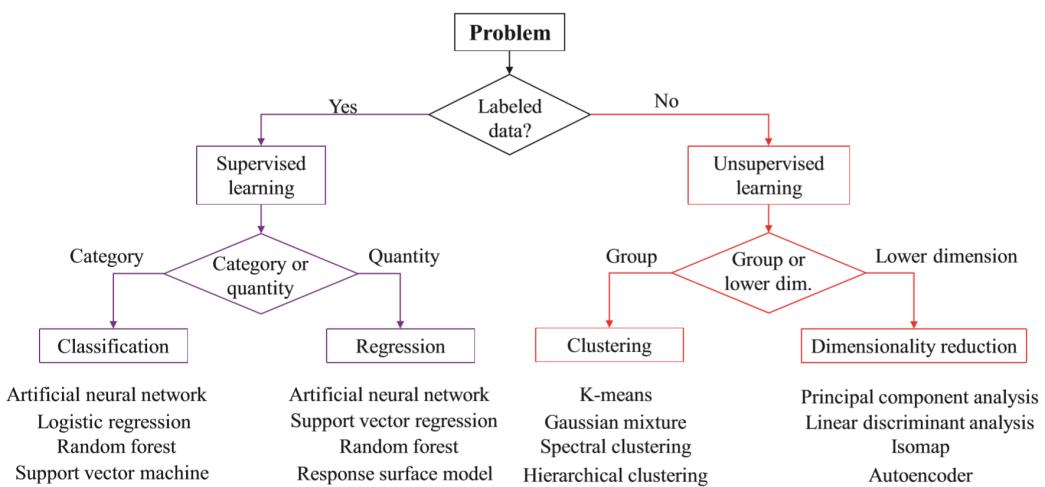


图 1 经常使用的机器学习算法

传统的机器学习算法在土木工程领域也得到了诸多应用。早在 2001 年，H. Adeli 等人^[4]就回顾了人工神经网络（Artificial Neural Networks, ANNs）与遗传算法（Genetic Algorithm, GA）、小波分析（Wavelet Analysis, WA）和模糊逻辑（Fuzzy Logic, FL）等不同计算范式的集成，在土木/结构工程中的应用。Adeli 目前还是美国俄亥俄州立大学的教授，西班牙皇家工程院院士，是土木工程和计算机交叉学科的先驱和杰出科学家。在土木工程领域做出了有影响力的、不可替代的、开创性的贡献，及其在推进计算机技术和信息技术在全球诸多工程领域应用过程中展现了非凡的领导力。其目前还是土木工程领域 Top1 期刊 Computer-Aided Civil and Infrastructure Engineering 主编，ASCE, , IEEE,

AIMBE 和 AAAS fellow。J. Zhang 等^[5]也基于模式识别技术，利用结构的振动信号对建筑结构的深层参数进行识别。之后，2016 年，Amezquita Sanchez 等人^[6]对 ANNs 在民用基础设施上的应用也进行了回顾。内容丰富，涵盖了多个主题，包括建筑工程和岩土工程等领域中的结构系统识别、结构健康监测、结构振动控制、结构设计和优化和预测应用等。M.H. Rafiei 和 H. Adeli 等也使用机器学习方法在结构损伤检测领域进行了探索^[7]。

最近，Yazhou Xie 等人^[8]针对 ML 在地震工程领域的研究和应用进行了全面的总结和综述，提炼出了在地震工程领域最广泛应用的 7 个 ML 算法和 4 大主题领域。7 个 ML 算法包括 ANNs, 支持向量机（Support Vector Machines, SVM），响应面模型

(Response Surface Model , RSM), 逻辑回归 (Logistic Regression, LR), 决策树 (Decision Tree, DT) 和随机森林 (Random Forest, RF)。此外, 还有多种方法结合的混合方法和一些比较应用不是那么广泛的方法比如计划计算 (Evolutionary Computing, EC) 和遗传表达式编程 (Genetic Expression Programming, GEP)。4 大主题领域是地

震危险性分析 (Seismic Hazard Analysis), 系统识别和损失检测 (System Identification and Damage Detection), 地震易损性评价 (Seismic Fragility Assessment) 和抗震结构控制 (Structural Control for Earthquake Mitigation)。这 4 个领域中, 采用不同机器学习算法的文章数量统计如下图 2, 图中的彩色圆圈越大, 则表示相关文献越多, 研究越广泛。

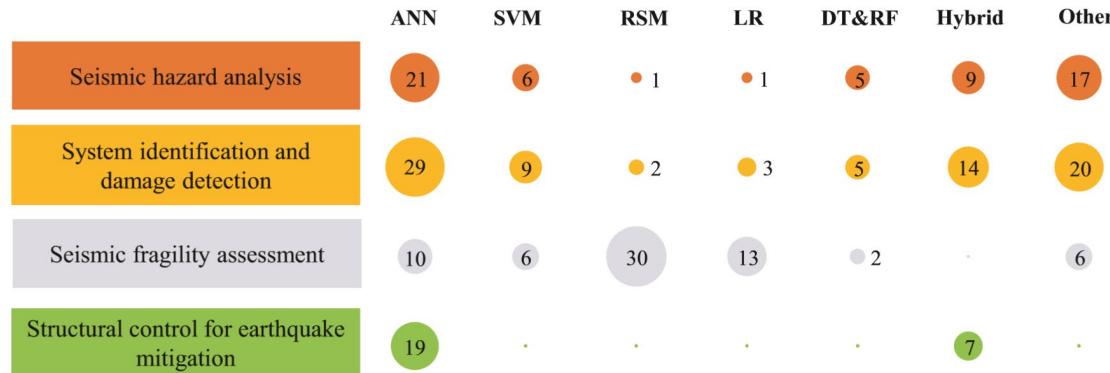


图 2 七类 ML 方法在地震工程四个专题领域的应用^[3]

地震危险性分析包括预测给定场地或位置的地震水平及其相关不确定性的研究。第二个主题是一个双重领域, 其中系统识别包括一系列研究, 这些研究利用 ML 模拟结构系统并预测其确定性地震响应, 而损伤检测被广泛定义为使用 ML 模型识别、分类和评估土木结构的地震损伤。第三个主题, 包

含各种不确定性来源的地震脆弱性评估是实践 ML 技术的一个有前途和流行的领域。第四个主题, 是装备 ML 的主动和半主动控制结构, 以减轻地震灾害的不利影响。ML 算法在这 4 个领域的应用示例如下图 3 所示。

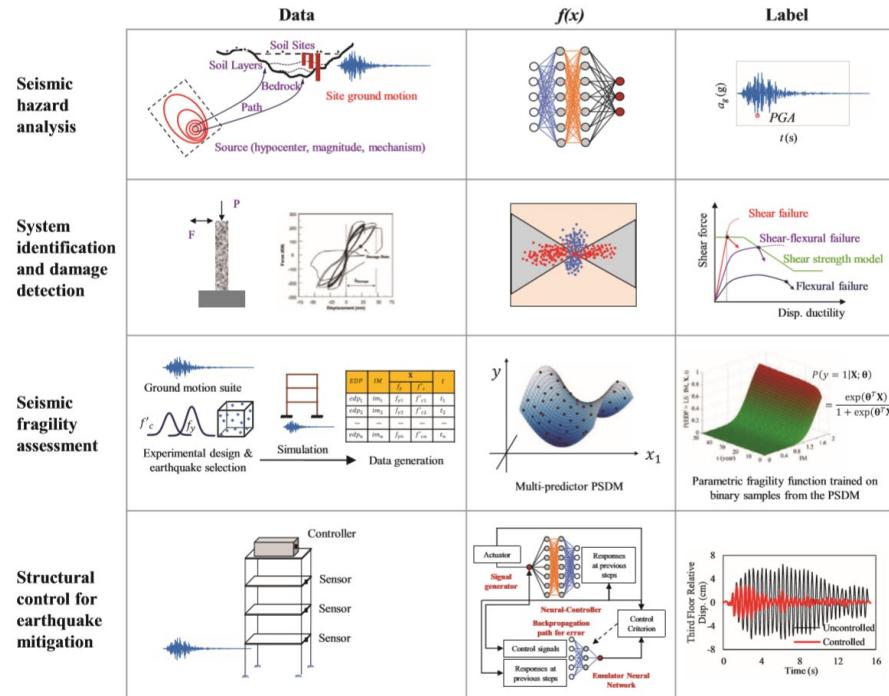


图 3 ML 算法在这四个主题领域的应用实例^[3]

还有诸多研究人员将 ML 方法应用于预测混凝土构件抗拉、抗压和劈裂强度中 (Estimating Concrete Strength) [8-9]。在该研究领域, 使用最广泛的 ML 方法有四种, ANNs^[10]、SVM^[11]、决策树和进化算法^[12] (Evolutionary Algorithms, EA)。基于这些算法, 提出了许多种模型设计方案, 这些模型不仅可以预测强度, 还可以还可用于敏感性分析, 指出预测过程中每个输入参数对混凝土强度的影响权重^[13]。基于机器学习方法预测混凝土强度的流程如下。首先基于大量的试验数据, 训练模型; 然后通过输入参数, 基于训练相关好的模型, 输出预测的混凝土强度。验证数据集提供对模型与训练数据拟合的无偏评估, 并通过在误差增加时停止训练过程来防止模型过度拟合。还有研究人员将神经网络与 FRP 钢筋混凝土梁理论相结合, 进行了钢筋混凝土梁的抗剪承载力估计等等^[14]。

深度学习^[15]是机器学习的一个重要分支, 是最近兴起的重要的, 具有变革性和颠覆性的技术。但是提及深度学习理论, 准确说并不新颖。早在 1986 年, 深度学习的思想就开始被引入机器学习理论当中^[16]。并且在 1999 年时被用于 ANNs 中^[17]。但是之所以没有在过去得到大规模的应用, 是因为在当时的计算机的计算能力与大规模神经网络计算的要求无法匹配, 因此深度学习理论更多的是停留在表面, 没有引起广泛的关注。近年来随着计算机硬件的发展, 计算能力逐步提高, CPU 的计算效率得到了几何级的增长。此外, NVIDIA 和 AMD 等公司开发的图形处理单元(Graphics processor unit, GPU)可以明显加速神经网络的训练速度, 这给深度学习得到大规模的应用, 提供了可能。2016 年, 由谷歌公司 DeepMind 团队开发的, 世界第一个围棋机器人 AlphaGo^[18]横空出世, 在这个人类开发的最复杂的智力游戏领域, 以 4:1 的比分战胜了围棋世界冠军, 职业九段选手李世石。事件引起了全世界的热议, 其背后的启发式搜索、强化学习和深度神经网络得到了人们的关注。很多人也是从那时候起, 第一次听说了一个名词, 深度学习(包括笔者自己)。紧接着, 更新版 AlphaGo Master 又以 3:0 的成绩完胜世界排名第一的中国选手柯洁, 登顶世界第一的宝座。并于 2017 年, 推出了 AlphaGo 的进一步增强版, AlphaGo Zero^[19]。其与初代 AlphaGo 机器人的成绩对比是 100:0。这一系列的举动, 不禁让人们想起了著名科幻电影《终结者》, 很多人也在怀疑,

难道人工智能已经可以取代人类了吗? (包括笔者自己)。经过这几年的了解, 笔者对深度学习的理解也逐步加深。离实现科幻电影中的强人工智能, 人类还有很长很长的路要走。比起 AlphaGo 下围棋事件本身, 其在人类历史上产生的深远影响, 是更有意义的。AlphaGo 毫无疑问是人类历史上的一次里程碑。AlphaGo 第一次将“深度学习”带入了世界广大人民的眼中, 也启发了更多的人加入深度学习的研究当中, 有力的推动了深度学习领域的发展和进步。

深度学习是一类模式分析方法的统称, 是从数据中自动学习并获取知识的智能科学。主要涉及 3 类方法, ①基于卷积运算的神经网络系统, 即卷积神经网络(CNN), 这是应用最为广泛的深度学习方法; ②基于多层神经元的自编码神经网络, 包括自编码(Auto encoder)以及近年来受到广泛关注的稀疏编码两类(Sparse Coding); ③以多层自编码神经网络的方式进行预训练, 进而结合鉴别信息进一步优化神经网络权值的深度置信网络(DBN)。与传统的 ANNs 相比, 基于深度学习思想设计的神经网络, 往往具有更深层的结构, 所以通常由称为深度神经网络(DNN), 通过多层非线性神经网络结构抽象和处理特征, 逐渐将初始的低维特征表示转化为高维特征表示后, 用“简单模型”即可完成复杂的回归、分类等学习任务。可以将其应用于有监督或无监督的特征表示和模式识别等方面。由此可将深度学习理解为进行“特征学习”(Feature Learning)或“表示学习”(Representation Learning)。具体实现上, 往往通过计算机编程, 设计神经网络结构, 用相对简单的网络结构来学习复杂的数据映射关系。在领域发展之初, 研究人员往往要自己实现神经网络的底层代码。近年, Caffe^[20]、Apache MXNet^[21]、Tensorflow^[22]和 Pytorch^[23]等神经网络框架的提出, 给相关从业人员设计神经网络模型、进行深度学习研究或者是基于深度学习进行工程应用提供了诸多便利。

目前以深度学习为代表的数据驱动算法, 已经被广泛的应用到了生产生活的各个领域之中, 已经被数十亿人使用。给计算机领域的数据挖掘、计算机视觉和自然语言处理等方向产生了颠覆性的影响, 这同时也极大促进了相关交叉学科的发展进步。给不同学科和方向都引入了变革性的解决方案。比如医疗卫生^[24]、自动驾驶^[25]、天文学^[26]和材料科学

^[27]等等，甚至是土木工程基础设施健康监测领域和病害检测领域^[28-29]。近年来，和 AI 结合已经成为土木工程领域一个热点和前沿的研究方向，机器学习和大数据理论的发展也给结构健康监测的发展带来了革命性的变化。深度学习也被誉为是继蒸汽技术、电力技术、计算机及信息技术之后的第四次工业革命。为了抢占人工智能的制高点，近年来全世界的投资都在急剧增加，高等学校也纷纷开设人工智能专业和相关课程。谁掌握了 AI，谁就掌握了未来。由于深度学习给当今世界带来了巨大的影响，为了表彰深度学习之父的 Yoshua Bengio, Yann LeCun 和 Geoffrey Hinton 的贡献，他们在 2019 年被授予了图灵奖 A.M. Turing Award（被誉为计算机领域的诺贝尔奖）。

结构损伤是工程结构固有的问题，其通常被定义为系统几何或材料特性的变化，对系统的性能、安全性、可靠性和结构的使用寿命产生不利影响^[30-31]。根据这一定义，结构的损伤并不总是表明系统完全失效，而是系统功能的相对恶化导致了结构性能下降^[32]。但是如果采取补救措施，损坏可能会累积，直至达到临界状态。结构系统可能会发生的突然失效，从而给人民的生命和财产安全带来损害^[33]。土木工程结构在服役期间内，会受到各种人为环境和自然环境的影响，会导致各种各样的损伤。并且损伤一旦发生，非常容易累积和传播。这些因素也会导致结构性能的不断退化，缩短结构的使用寿命^[34]。比如结构在服役期间自身的蠕变、收缩和疲劳，受到外界环境影响会发生锈蚀，受到极端情况比如台风和地震会发生破坏等等^[35]。这些都在不同程度上影响土木工程基础设施的健康状态，如果不提前检测、预警和保养，非常容易导致结构在设计使用年限内发生不可逆转的破坏^[36]。比如，钢桥吊杆腐蚀或疲劳产生吊杆的突然断裂，从而导致桥梁整体垮塌。在 2019 年的 10 月 1 日，中国台湾宜兰县的南方澳跨海大桥一座跨海大桥就是因为这个原因发生垮塌，事故造成 6 人死亡，12 人受伤。因此，对基础设施进行合理的常态化的检测，评估结构的健康状况，并对结构损伤提供早期预警至关重要，很多研究人员也在这方面进行了大量的研究^[29,37]。

目前，**结构的损伤监测**主要包括两大类，即结构的健康监测（Structural Health Monitoring, SHM）和结构的损伤检测（Structural Damage Detection，

SDD）。

SHM 通常是基于相关设备记录的结构响应，来定位和评估结构损伤，并对结构健康状况做出判断和决策^[38]。它是一个广泛且高度跨学科的研究领域，涉及环境和操作条件的长期测量、数据采集和管理、参数和系统识别等等^[39]。SHM 系统已经在机械工程、航空航天和土木工程等领域都得到了广泛的应用^[40]。最成功、最成熟的损伤检测系统是机械工程中用于机械零件振动状态检测的系统^[41]。这种系统利用机器在位移、速度或加速度方面记录的振动响应来评估其轴承和齿轮的安全状态^[42]。但是机械的振动响应受人工操作和环境条件的影响很小，这意味着系统振动特征的任何显著差异都可以归因于某种类型的损伤。由于机械损伤的类型和位置是明确定义的，因此将振动特征的每个变化与特定的损伤类型和位置相关联是非常可行的^[43]。最近，在机械工程领域也有很多研究人员将人工智能和深度学习技术应用到机械结构的健康监测当中^[44-45]。例如，W. Zhang 等^[46]提出一种卷积神经网络模型用于研究噪声环境和不同工作负荷下的轴承故障诊断，T. Ince 等人^[47]则将卷积神经网络应用于都检测电机故障。

基于振动的机械状态监测方法的成功促使研究人员在民用基础设施的 SHM 中实施类似的技术。但是土木工程领域，结构的损伤类型和损伤对结构安全性的影响的机理非常复杂，且结构受外在环境的影响很大，因此土木工程领域的结构健康监测是一个更大的挑战。一个典型的 SHM 系统由软件和硬件组成，如下图 4 所示。硬件部分由用于测量和收集数据的传感器和数据采集接口组成，通常包括加速计、速度计、应变计、称重传感器或光纤传感器以及数据采集模块组成^[48]。损伤检测系统的软件组件是一个信号处理和模式识别算法库，用于将传感接口获取的信号转换为反映被监测结构状况的基本信息^[49]。

病害检测算法是 SHM 系统的核心，一个优秀的病害检测算法，需要能够从系统整体出发，自动判断损伤是否存在、定位损伤发生位置并评估或量化损伤的严重程度，从而对结构整体性能进行评估。大量的研究人员也在该领域进行了广泛的探索和研究^[28]。最近，国内外也有很多研究人员提出将深度学习应用于结构工程的监测领域，具体工作将在本文的第 3 节进行详细展开。

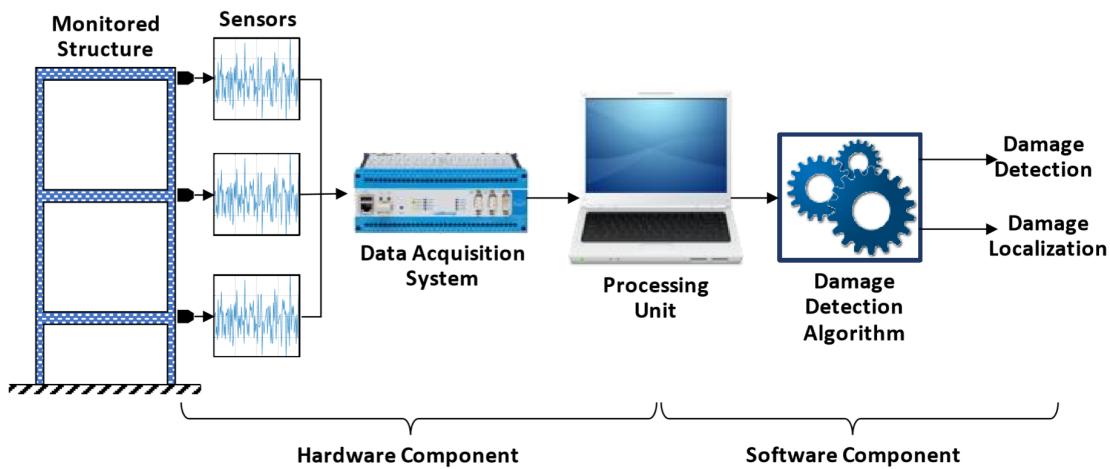


图 4 常规 SHM 系统的主要构成^[28]

SDD 则通常是通过人工的方法进行接触式或非接触式的检测，直接定位并量化结构的损伤^[50]。传统的土木结构损伤诊断方法主要是基于人工的视觉检测。这种传统的检测方式存在着诸多弊端^[36]。

(1) **巡检盲区多。**大跨径桥梁结构复杂，许多区域人工都难以有效检查，存在较多的检测盲区。例如混凝土结构结合部、索塔外表面、深水基础、峡谷区域的主梁梁底等。

(2) **人力或设备成本高昂。**传统方法需要借助脚手架、检测车设备，土建结构的尺寸相对较大，定期检查也要花费大量的人力和物力。以传统检测车方法为例，固定设备成本 1.5 万元/千米，人力成本 0.67 万元/千米，设备租赁成本 4.2 万元/千米，设备损耗费用 0.0073 万元/千米，其他直接费用 0.2 万元/千米，相关间接费用 0.15 万元/千米，经济总成本高达 5.23 万元/千米。

(3) **智能化程度低，检测效率低下，精度较低**^[51]。人工检测主要依靠人力，智能化程度很低，检测效率难以满足需要。传统检测工具精度不足。传统的检测方法主要采用卷尺、全站仪、千分尺等常用的测试仪器对被测项目进行测量，测量精度只能达到毫米水平，测量精度较低。并且人工检测存在一定的随机性和不确定性，依赖人的主观判断，检测效果难以保证。

(4) **安全风险较大。**检测人员以传统方式进行户外作业存在较高的安全风险，例如在进行拉索的检测时，检测人员通常会乘坐吊篮进行高空作业，稍有不慎就会酿成安全事故。下图 5 为部分人工检测工作的图示。



(a)



(b)



(c)



(d)

图 5 人工检测方法：(a) 桥梁检测车检测，(b) 桥梁底部病害检查，(c) 裂缝检测，(d) 拉索检测

目前，人们也将多种非接触式的方法应用于基础设施的病害检测当中，比如基于三维扫描、工业相机和微波雷达等等。也开发了多种先进设备，比如拉索机器人、无人机等用于基础设施的病害检测。

下图分别为三维扫描设备、光测方法、微波雷达方法和无人机进行桥梁结构的动静态变形、拉索索力和表观病害等信息的检测。(部分图片为笔者在今年6月期间参与的试验中拍摄。)除了采用先进的设备，人们还基于人工智能和大数据分析基础等先进算法，提出了许多适合于结构检测的新方法^[29]，取得了不错的工程应用效果，具有广泛的应用前景。希望这些先进的智能的技术和方法早日成熟，并进行大规模的工程应用，解放人类的生产力，保护结构健康！中国东南大学张建教授团队在非接触智能化结构检测领域进行了广泛的研究并取得了一系列进展，包括人工智能算法检测裂缝^[52-53]、无人机实时病害检测^[54]、基于无人机和计算机视觉的非接触式索力测量^[55]、基于微波雷达的大跨度斜拉桥和悬索桥的索力估算等等^[56]。该领域具体的技术和研究进展将在本文的第4节、第5节和第6节进行细致的讨论。

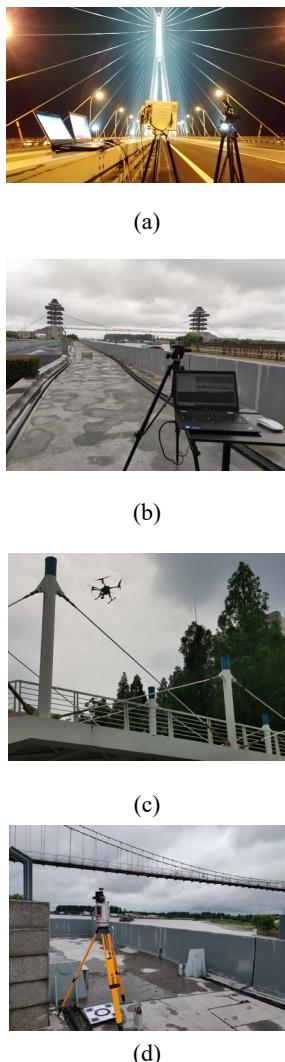


Fig. 6 Non-contact equipment. (a) Microwave radar; (b) Industrial camera; (c) UAV system; (d) 3D laser scanning equipment.

图6 非接触式检测设备：(a) 微波雷达，(b) 工业相机，(c) 无人机系统，(d) 三维扫描设备

本文综述了近几年来，基于深度学习方法的，在结构病害检测和结构健康监测领域做出较大创新和贡献的前沿研究。为了凸显逻辑性，将内容划分为三个部分。分别是一维数据研究、二维数据研究和三维数据研究。一维数据主要是基于传感器信号的结构健康研究，二维数据主要是基于图像数据的病害检测，三维数据主要是关于基于三维扫描的点云数据进行数字孪生相关的研究，比如结构建模和有限元分析。本文的具体内容安排如下。第2节回顾了计算机科学领域，深度学习技术的发展，这是当前与土木工程交叉方向的核心驱动力。了解并紧跟原领域的发展，才能更好进行交叉学科的研究。第3节介绍了深度学习在结构健康监测领域的最新进展（一维数据）。第4节则详细阐述了在基于深度学习的病害识别研究。相比于一维传感器数据，病害检测与计算机视觉相关。计算机视觉是当前深度学习发展两大方向之一（计算机视觉和自然语言处理），因此病害检测也得到了更多研究者的关注。第5节则讨论了在三维数据领域的相关研究。该领域相对前面两个领域，更加新颖且难度较大，目前的研究相对较少。第6节则从智能检测设备出发，回顾了在结构检测领域智能检测设备的研究进展。最后，第7节是本篇文章的主要观点的总结和对该交叉领域未来发展的展望。旨在推动该领域的进一步发展。

2 深度学习方法

2.1 概述

深度学习理论在20世纪后半叶提出，并不断的发展完善，扩充了机器学习的谱系，现已经成为机器学习的重要组成部分。除了按照第一节中介绍的有监督方法和无监督方法来划分机器学习算法，还可以基于算法特性进行划分。可以划分为聚类分析(Clustering)，贝叶斯方法(Bayesian)，回归分析(Regression)，实例分析(Instance Based)，神经网络(Neural Networks)，决策树(Decision Trees)，

集成学习（Ensemble Learning），数据降维分析（Dimensionality Reduction）和深度学习（Deep

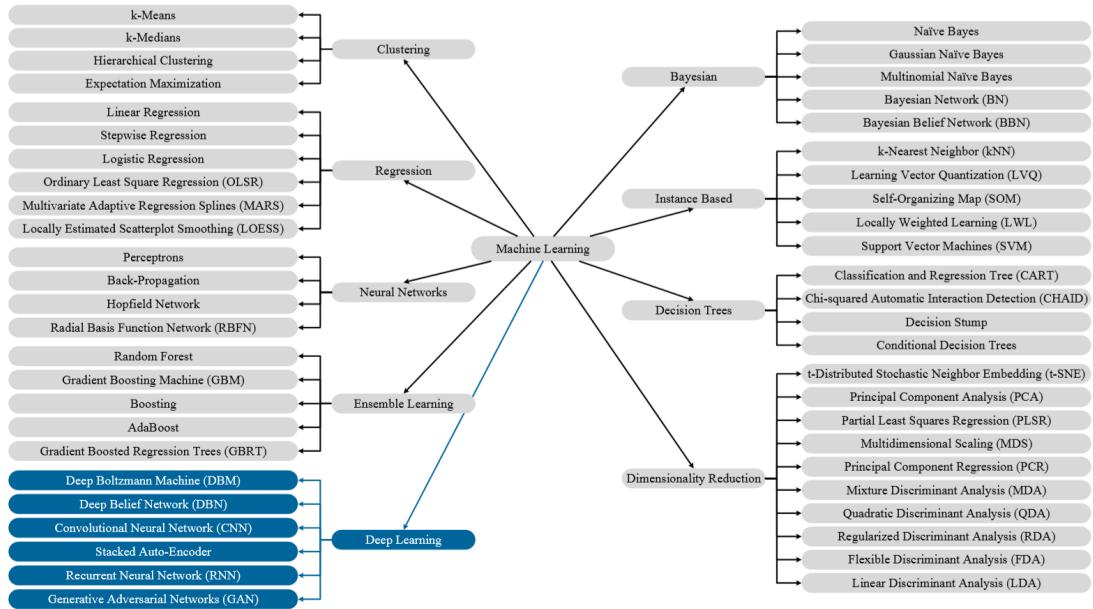


图 7 机器学习算法思维导图^[29]

深度学习促进了现代计算机科学的极大进步，在解决计算机视觉、自然语言处理、语音识别和机器人技术等领域的长期问题方面取得了极大进展。同时，也在很多领域替代了传统的机器学习算法。

在深度学习之前，数据的分类和回归领域使用最广泛的算法之一就是 SVM^[57]。SVM 是一种二值分类算法，它利用核函数将数据隐式映射到高维特征空间当中。对于如下图 8(a)中所示的可分离数据，SVM 算法执行最佳边缘分类器以构造分离超平面，该分离超平面可以最大化超平面和支持向量之间的边缘的距离，支持向量包括最接近超平面的数据

Learning)。具体分类如下图所示。

点。

除了进行数据分类，支持向量机还可以作为一种回归方法^[58]，对于 ε 不敏感区域，误差均视为 0。如下图(b)所示，通过非线性核映射，SVM 可以在高维特征空间中进行线性回归，同时加入松弛变量来测量 ε 不敏感区外训练样本的偏差^[59]。在深度学习兴起之后，SVM 的研究热度逐渐下降。深度学习技术有更强的非线性拟合能力，这使得它在数据分类和回归诸多传统的机器学习任务上，都能取得让人满意的效果，深度神经网络逐渐取代了 SVM。

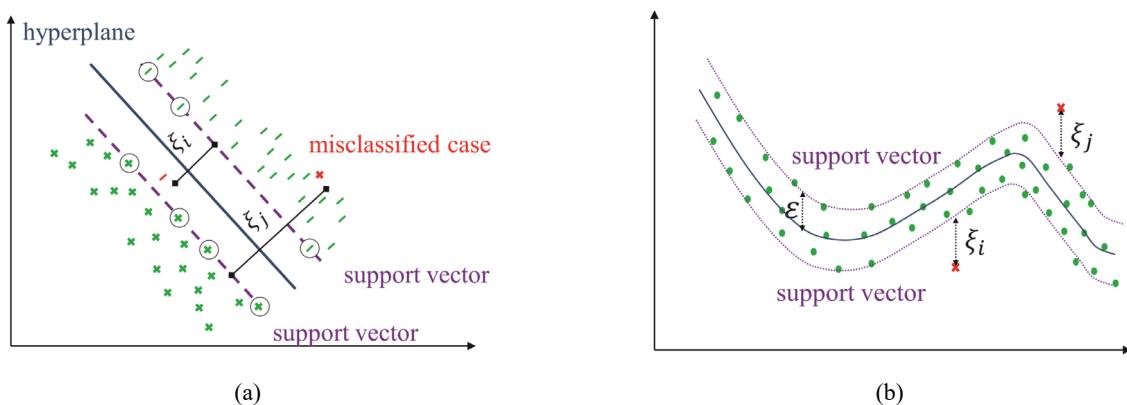


图 8 SVM: (a) 分类, (b) 回归

计算机领域发表的文章主要发表在顶级会议上。中国计算机协会（China Computer Federation，

CCF）规定的 A 类会议和部分顶级 B 类会议，包括 IEEE Conference on Computer Vision and Pattern

Recognition(CVPR), IEEE International Conference on Computer Vision(ICCV), European Conference on Computer Vision(ECCV), AAAI Conference on Artificial Intelligence(AAAI), International Joint Conference on Artificial Intelligence (IJCAI) and Conference and Workshop on Neural Information Processing Systems (NeurIPS), International Conference on Learning Representations(ICLR)等等。在深度学习之前,这些国际顶级会议的论文通常都是各种机器学习算法或者是传统方法占据。自从深度学习成为研究热门之后,这些顶级会议录用的论文无一例外,绝大多数都转为了研究深度学习的论文,并且会议的投稿量近两年迎来了爆发式的增长。2020年6月举办的CVPR 2020,投稿量超过了6000篇,而AAAI 2020的投稿量甚至超过了8000篇。下图9是CVPR历年的投稿数量,下图10是AAAI历年的投稿数量。大概从2015年开始,投稿量开始出现井喷式的增长,这也是深度学习开始热门的时间点。投稿量的迅猛增长,直接体现了这个领域的热门程度,受到了来自全世界研究者的关注。



图9 CVPR历年投稿

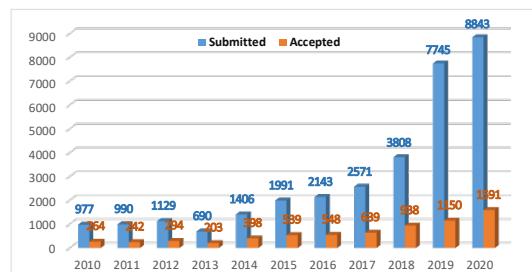


图10 AAAI历年投稿

与投稿量直接相关的,也就是优秀工作被引用量的飞速提升。比如2016年的CVPR, Kaiming He提出了Deep Residual Network (ResNet)^[60],这种独特的残差网络结构设计,有效解决了神经网络随着

网络深度的加深,会出现退化,从而难以有效训练的问题。这项工作使得深度神经网络成为了可能,作为骨干网络(backbone)被引入后续大量的研究当中。下图是ResNet中,最重要的shortcut设计。截止2020年7月,论文的引用量已经达到了26776次!(数据来源Research_Gate)这在其他领域比如土木工程领域是很难想象的。

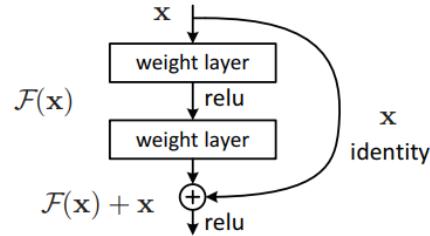


图11 残差网络: Shortcut

目前基于深度学习的计算机视觉研究主要是将深度学习引入图像识别处理任务中,使用深度学习技术对图像处理进行建模。计算机视觉技术使用深度学习来识别解释图像,就像人类视觉的视觉推理过程一样,计算机视觉技术可以区分对象,对它们进行分类,根据它们的大小对它们进行排序等,其将图像作为输入,并以大小,颜色强度等信息的形式提供输出。

目前计算机视觉任务主要有图像分类(Classification)、目标检测(Object Detection)、语义分割(Semantic Segmentation)、实例分割(Instance Segmentation)、姿态估计(Pose Estimation)、增强和恢复(Enhancement and Restoration)以及动作识别(Action Recognition)等。下面对CV领域的一些经典的网络结构进行简要介绍。

2.2 二维数据处理

目前,在基于深度学习技术进行二维数据处理领域,最广泛使用的是卷积神经网络。这是一种多层次网络学习算法,具有表征学习(Representation Learning)能力,通过不断地卷积等运算提取压缩图像特征,最终形成比较高层次特征,按其阶层结构对输入信息进行平移不变分类,其基本组成有卷积层、池化层、全连接层。

2012年,Krizhevsky等设计了AlexNet^[61],成功使用了ReLU作为CNN的非线性激活函数;使用Dropout操作忽略部分神经元,有效避免了模型的过拟合;摒弃平均池化操作,广泛使用最大池化

操作。AlexNet 的诸多创新尝试，给后续的 CNN 模型设计提供了宝贵的经验，ReLU 和最大池化等操作后续也得到了广泛的应用。其在 2012 年 ImageNet 大规模图像识别挑战赛(ILSVRC)中获得冠军，测试

误差为 16.4%，比使用非深度学习方法的误差低得多。在此之后，CNN 在计算机视觉领域引起了越来越多研究者的关注，也得到了广泛的应用。下图是 AlexNet 的网络结构示意。

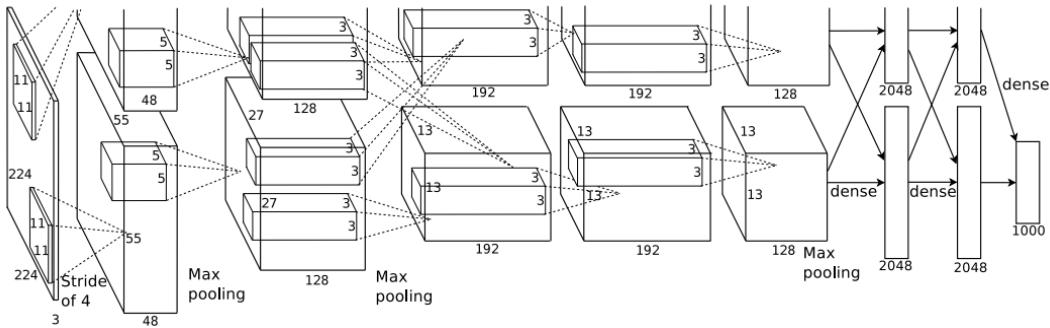


图 12 AlexNet 结构示意图

2014 年，Google 公司提出的 InceptionNet（也叫 GoogleNet）结构^[62]采用分解卷积，并以采用平均池化层来代替全连接层，在控制计算量，保证计算效率的同时，提高了网络的性能。该网络拿到了 ILSVRC 挑战赛的第一名，将 Top5 的错误率降低到 6.67%。InceptionNet 最大的创新是提出了多分支网络设计思路（Multi-branch Network），该设计思路可以学到非常多样性的特征。在该网络中，率先使用了 Batch Normalization 操作，该操作可以①提高训练速度，加快网络收敛；②提高模型的泛化能力，防止过拟合。网络的分支模块如下图所示。

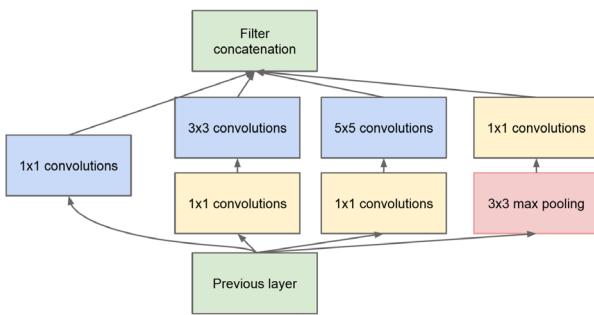


图 13 网络分支模块

与 InceptionNet 同时期的 VGG 网络^[63]指出网络的深度（Depth）是算法优良性能的关键部分，将 Top-5 错误率降到 7.3%，拿到了第二名的成绩。VGG 也是一个非常经典的卷积神经网络设计，首先提出了模块化网络设计思路（Modular design），将网络分为宏观结构（网络包括不同的阶段 stage）和微观结构（block 设计）。这是一个具有开创性并且在今天依然被广泛使用的设计思路，可以有效简化

网络设计思路。

后续研究发现，单纯的堆积网络深度，可能会产生梯度消失、模型准确率反而降低、模型退化等系列问题。2015 年，ResNet 网络^[60]（深度残差网络），引入了跳跃连接，直接学习网络的残差，过滤网络的冗余信息，在反向传播时，相加的部分可以在一定程度上减少梯度消失；拿到了 2015 年 ILSVRC 第 1 名。其平均错误率仅为 3.57%，而人眼的平均识别错误率为 5.1%。这是在该项比赛中，第一个超过人眼的识别精度的算法，此外，其识别速度也远快于人眼速度。此后 ResNeXt^[64]、DenseNet^[65]等网络在 ResNet 的基础上相继提出。DenseNet 基本思路与 ResNet 一致，但是其建立了所有层与后续层的密集连接(dense connection)，实现特征重用(feature reuse)，可以在参数和计算成本更少的情形下实现更优的性能，获得了 CVPR 2017 的最佳论文奖。下图是一个 5 层 Dense block 设计。

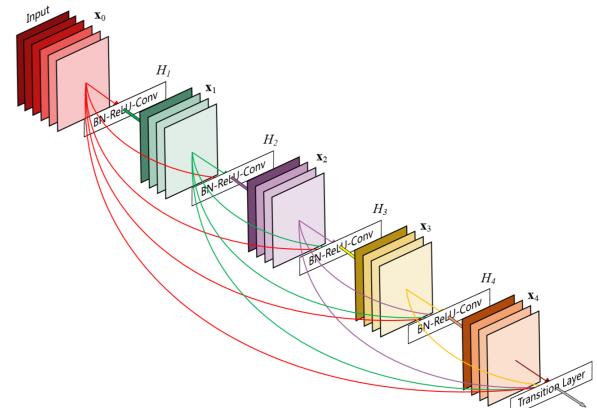


图 14 5 层 Dense block

2017 年, SENet[66]采用考虑特征通道的关系,通过 Squeeze 和 Excitation 模块,在特征通道中引入了注意力机制,直接学习每个特征通道的重要程度因子,依照这个因子提升有用的特征并抑制无用特征。该网络拿到了当年 ImageNet 比赛的第 1 名,将 top-5 错误率降低到 2.25%。Squeeze 操作为

$$z_c = F_{sq}(u_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j) \quad (1)$$

Excitation 操作为

$$\begin{aligned} s &= F_{ex}(z, Wp) = \sigma(g(z, Wp)) \\ &= \sigma(W_2 \text{ReLU}(W_1 z)) \end{aligned} \quad (2)$$

其中, W 和 H 是宽度和高度尺寸, u_c 为特征矩阵, z 为全连接层, Wp 为超参数, W_1 为缩放因子, W_2 也是全连接层。下图为 Squeeze 和 Excitation 模块示意图。

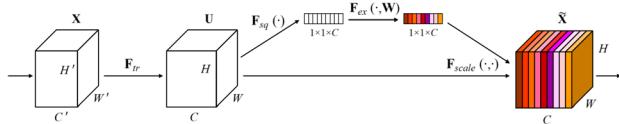


图 15 一个 Squeeze-and-Excitation 模块示意图

注意力机制最先在自然语言处理领域得到了广泛应用,自 SENet 之后,注意力机制开始应用到 CV 领域,并成为最近几年非常热门的研究方向。 Sanghyun 等人^[67]结合了特征通道和特征空间两个维度的注意力机制,提出了 CBAM。与 SENet 相比, CBAM 增加了最大池化的特征提取方式,将通道注意力提取后的特征作为空间注意力模块的输入。后续 Gao 等人^[68]提出了 GSOP-Net, Bello 等提出了 AANet^[69], 使用可以共同参与空间和特征子空间的注意机制,引入额外的特征映射。首先通过矩阵运算获得注意力权重图,通过多 Head 操作赋值多个空间,在多个空间内进行注意力点乘,实现自注意力机制。2020 年,东南大学 2013 级校友,亚马逊青年科学家张航 2020 年提出了 ResNeSt 拆分注意力网络(Split-Attention Network)^[70]。该网络作为骨干网络(backbone),在图像分类、目标检测、实例分割和语义分割等多个任务中,均取得了 SOTA 的结果。拆分注意力网络如下图所示,

上述主要介绍了一些经典的,在多种计算机视觉任务中取得较好效果的骨干网络,骨干网络也是其他卷积神经网络的基础,很多在不同任务中取得效果的专用网络都在不同程度上借鉴了骨干网络。

下面简要几个不同计算机视觉任务中非常经典的工作。

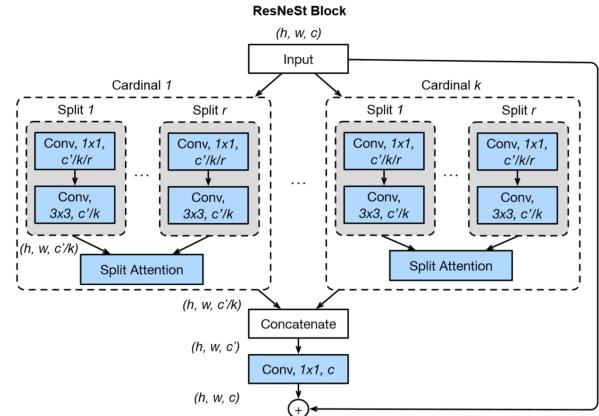


图 16 ResNeSt 示意

目前基于深度学习的目标检测有两个主要发展方向: Two Stage 的目标检测算法和 One Stage 的目标检测算法。前者的思路是先由算法生成系列候选框(正/负样本),再由卷积神经网络对样本进行分类;后者则不采用候选框生成思路,而是由回归来对目标进行定位;前者在检测准确率和定位精度上占优,后者在算法速度上占优。2014 年, Ross B.Girshick 等人^[71]提出 R-CNN 算法, R-CNN 算法通过选择性搜索(Selective Search)算法生成构成正负样本的候选框并输入到卷积神经网络结构中,通过卷积网络分别对正负样本进行特征提取并形成相应的特征向量,最后支持向量机(SVM)设计分类器对特征向量分类,并对候选框进行回归得到目标坐标以及类别信息。R-CNN 相较于传统目标检测算法取得了 50% 的性能提升。2015 年, Ross B.Girshick 等人又提出一种改进的 Fast R-CNN 算法^[72],采用 ROI Pooling 作为新的池化层,对候选框区域对于的特征图进行池化运算,有效克服了 R-CNN 输入图像尺寸固定的缺点。2015 年, Ren 等人^[73]提出了 Faster R-CNN 算法,设计了生成候选框的全卷积子网络 RPN(Region Proposal Networks)网络,算法流程主要有两个阶段组成,图片先通过骨干网络生成特征图,然后经过 RPN 网络生成系列候选框并进行坐标的初步回归以及前/背景的分类,再经 R-CNN 头部网络对前一步生成的候选框进行进一步细化分类和坐标回归,整个流程共享由骨干网络提取出来的特征图信息,节省显存。下图是 Faster R-CNN 网络的结构示意。

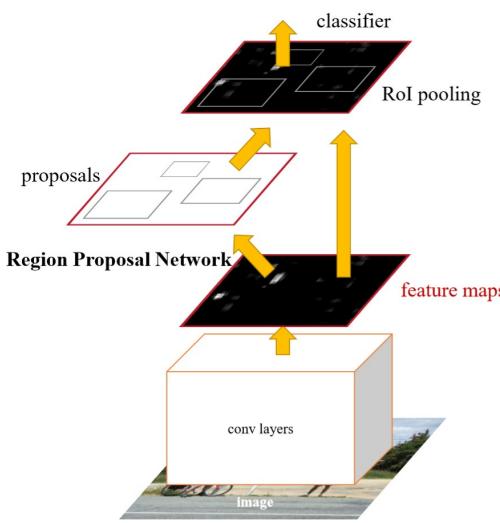


图 17 Faster R-CNN

2015 年, Joseph Redmon 等^[74]提出基于回归的 One Stage 方法 YOLO (You only look once) 算法基于图像的全局信息进行预测, 将图像划分为 7×7 网格窗口, 通过卷积网络提取特征训练, 对各网格内边框的坐标信息和各类别置信度进行预测, 激活函数选用的是 PReLU, 速度能达到每秒 45 帧; 不足之处是定位不准并对小物体检测效果较差。2016 年, 针对 YOLO 类算法的定位精度问题, Wei Liu 等^[75]提出 SSD 算法, SSD 组合了 YOLO 中直接回归坐标和类别信息的思想以及 Faster R-CNN 的 Anchor 机制生成合适的候选框的思想, 并在不同尺度的卷积层特征图上均进行结果预测, 输出的预测边框坐标是多尺度的结果, 在整幅图像上使用不同尺度的局部特征在各个位置进行边框回归。一方面保持了 YOLO 算法实时性, 另一方面也满足了一定的边框定位效果, 不足之处是对于小目标检测困难。之后, SSD 网络和 YOLO 网络又出现了不同的改进型, 比如 YOLO 网络在 2016 年推出了 YOLOv2 网络^[76], 在 2018 年推出了 YOLOv3 网络^[77], 并在 2020 年推出了 YOLOv4 网络^[78]。每一个版本的 YOLO 网络都因为其兼具高效率和高精度而饱受赞誉, 在工业界得到了广泛应用。下图是 YOLOv4 网络和其他主流网络的对比。

在语义分割领域, 2015 年, Shelhamer 等人^[79]提出了 FCN 网络, 是基于深度学习进行语义分割的开山之作。FCN 网络将传统 CNN 中的全连接层, 全转化为了卷积层, 所以取名 Fully Convolutional Networks。网络允许任意尺寸图像的输入, 具有较

好的适用性。基于 FCN 的网络框架, Ronneberger 等人^[80]提出了改进网络 U-NET, 因为网络结构类似于大写字母 “U”, 故得名。与 FCN 不同, U-NET 采用了基于拼接的特征融合方式, 提高了通道的深度。目前, U-NET 在医学图像处理领域得到了广泛的应用。下图为 U-NET 的结构示意图。

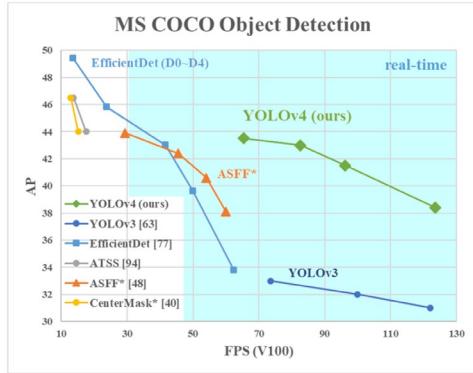


图 18 YOLOv4 与主流网络比较

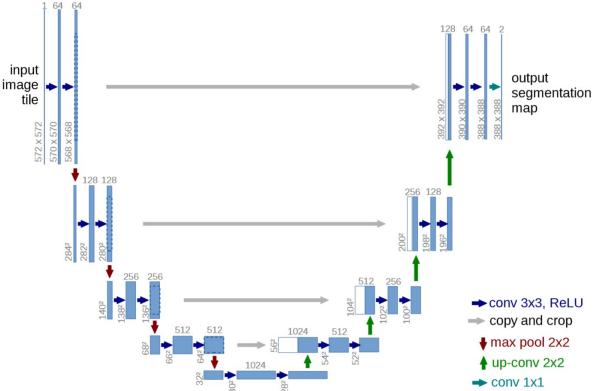


图 19 U-NET 结构

2017 年, 何恺明等人^[81]提出了 Mask R-CNN 算法, 使用 ROI Align 替换了 Faster R-CNN 网络中的 ROI Pooling, 并对 R-CNN 头部进行扩展, 并添加了语义分割分支 FCN 层 (Mask 层), 对目标的掩码进行预测, 实现像素级的语义分割。该网络思路清晰, 效果卓越, 自提出之日起, 就成为了语义分割领域的标杆算法, 后续算法均不可避免的与之进行比较。Mask R-CNN 网络结构如下图所示。

图 18 中, 被对比的一个经典网络名为 EfficientDet^[82], 该网络是 Google 公司研究团队于 2019 年提出的 SOTA 网络, 几乎在所有的数据集上都得到了最优的结果, 同时还有很高的计算效率。其以之前 SOTA 的网络 EfficientNet^[83]为主干网络,

使用 BiFPN 作为特征网络，并使用共享的边界框/类别预测结果。识别效果远超 Mask R-CNN, RetinaNet 和 YOLOv3 等在内的主流网络结果。下图为 EfficientDet 和不同网络的对比结果。这里要说明的是，由于一种网络往往可以胜任多种计算机视觉任务，因此下图中才会同时比较 YOLOv3 和 Mask R-CNN。

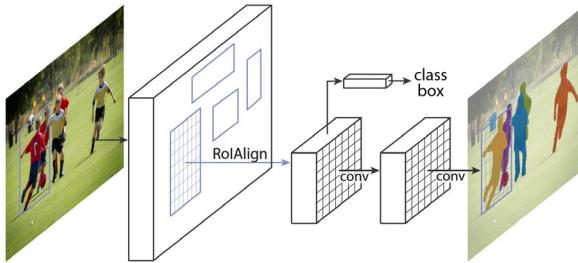


图 20 Mask R-CNN

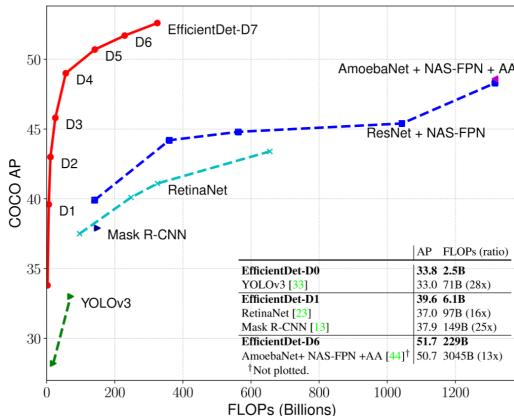


图 21 不同网络结果对比

2.3 一维数据处理

之前在深度学习领域的研究，更多的是基于卷积神经网络进行。最近，基于数据驱动方法，发现隐藏的物理 laws 引起了越来越多人的关注。人们利用现代机器学习技术，特别是深层神经网络，进行了偏微分方程和常微分方程的建模和恢复，并取得了一系列进展^[84-87]。比如一种新型 physics-informed neural networks (PINNs)^[88]最近得到了广泛研究。该方法基于自动微分算法，将物理信息约束嵌于神经网络之中，可以有效进行适定偏微分方程和常微分方程的建模和 PINNs，比如 Burgers' Equation 和 Allen-Cahn Equation 等。Maziar Raissi 等^[89-90]还将 PINNs 用于模型反问题求解之中，取得了非常好的效果，比如 Kortewegde Vries Equation 等。此外，他

还将 Navier-Stokes equations 编码到神经网络之中，可以有效进行流体力学建模^[91]。众多研究人员将 PINNs 在领域的应用进行了研究。Ehsan Haghighat 等^[92]基于 PINNs 建立了线弹性固体力学解与发现的模型，M. Torabi Rad 等人^[93]将 PINNs 应用于合金凝固基准问题的研究当中。尽管 PINNs 在诸多方面的应用都取得了成功，但是对于其收敛性的理论研究还处于起步阶段。YEONJONG SHIN 等^[94]基于 Schauder approach，证明了其可以强收敛于 PDE 理论解，这是第一个 shows the consistency of the PINNs methodology，奠定了 PINNs 的理论基础。下图 22 为 Burgers 方程的正问题求解，可以看到 PINNs 方法可以获得非常高的求解精度。下图 23 为适用于求解线弹性固体力学解的网络结构。

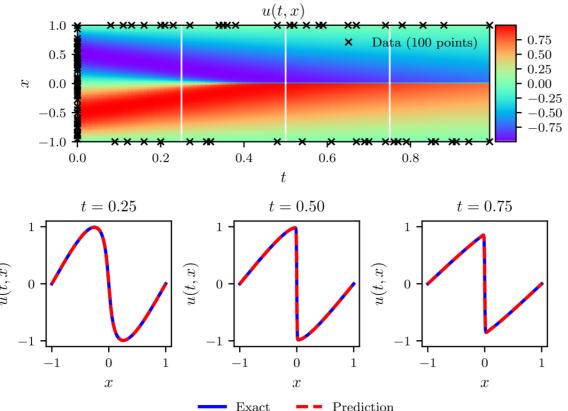


图 22 Burgers equation 求解^[88]

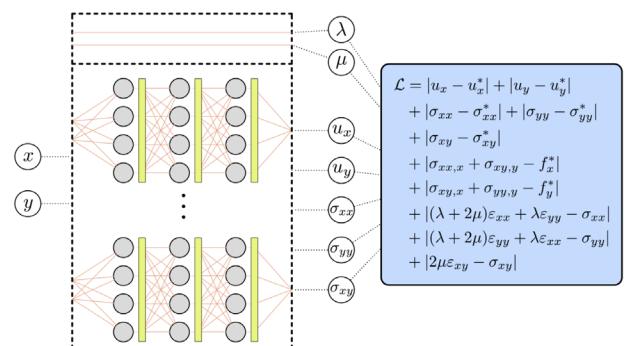


图 23 网络结构设计^[93]

2.4 三维数据处理

随着激光雷达等三维扫描设备的发展，三维数据的重要性逐步提升，在自动驾驶、SLAM (simultaneous localization and mapping) 等领域有诸多应用。处理三维数据的深度学习方法最近也得到了广泛关注。三维深度学习主要包括多视角、体

素和点云三类。多视角是将多视角的二维图片组合为三维物体；体素则是将物体表现为空间中的体素进行类似于二维的三维卷积；点云则是直接将三维点云数据导入三维卷积网络中进行处理。

牛津大学 Wu 等人^[95]基于自编码器结构，提出了一种无需外部监督即可从原始单视图图像中学习 3D 变形对象类别的方法。可以在不需要监督的情况下，可以从单张图像中重建物体的三维形状，该论文获得了 CVPR2020 最佳论文奖。Chen 等人^[96]则提出了一种无监督方法，生成紧凑的结构化多边形网格，可以进行三维数据的分割和重建。其分割和重建效果与其他方法对比如下图。该论文也获得了 CVPR 2020 最佳学生论文奖。三维数据的处理、分割和重建等方向是一个非常有前景的方向，预计在未来也会得到更多的关注。

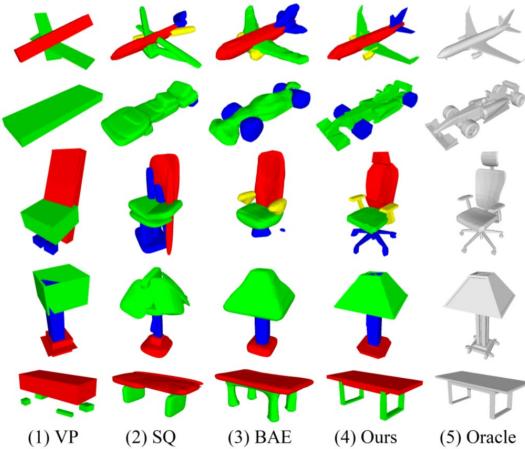


图 24 分割重建和量化

点云数据存在无序性和旋转性两大特点，即点的顺序不影响空间中对整体形状的表示，相同的点云在空间中经过刚体变化，坐标会发生变化，加之数据量庞大，这导致了处理三维数据的难度要远大于二维数据。

直到 2016 年年底，斯坦福大学 Qi 等人^[97]才提出了第一个可以直接进行点云数据分类和分割的深度学习框架 PointNet。PointNet 通过空间变换网络解决旋转问题，通过 maxpooling 解决无序性问题，提取整体特征。网络的基本思路是对输入点云中的每一个点学习其对应的空间编码，之后再利用所有点的特征得到一个全局的点云特征。该论文也发表在 2017 年的 CVPR 会议上。

后续，作者们又提出了改进版的网络框架 PointNet++^[98]。因为在实际测试中 PointNet 无法很好捕捉由度量空间引起的局部结构问题，由此限制了网络对精细场景的识别以及对复杂场景的泛化能力。复杂结构的细部特征往往不能很好地分割。加之 PointNet 网络中对点云进行的是均匀采样，而实际场景中的点云数据往往疏密不同，均匀采样并未考虑这些特性行。改进版网络 PointNet++则更加关注对局部结构特征的处理，同时考虑了疏密不同的点云数据，这样可以有效提高识别精度。这项工作发表在 2017 年 NeurIPS 会议中。至此，三维点云数据的处理也获到了越来越多研究人员的关注，PointNet 和 PointNet++网络也启发了大量的研究人员。PointNet++网络结构如下图所示。

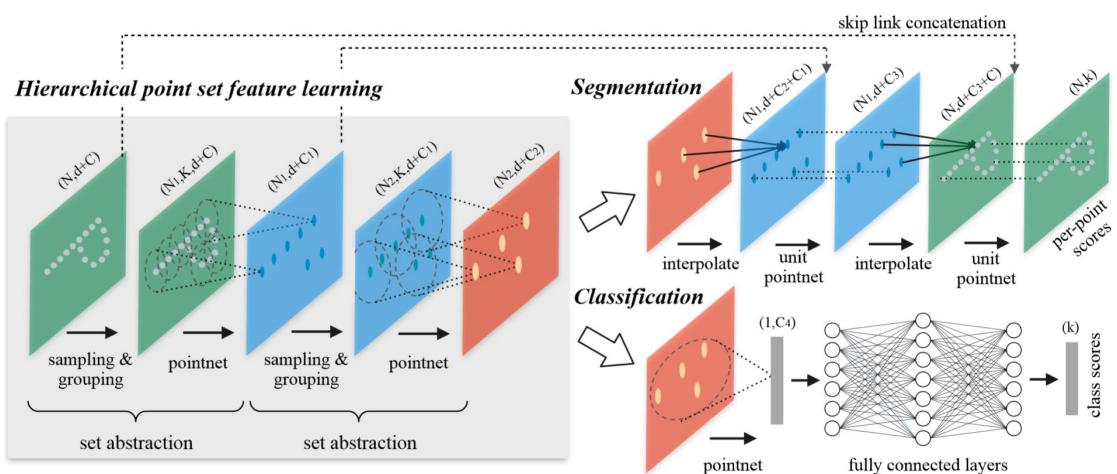


图 25 PointNet++网络结构图

最近两年，Ben-Shabat 等人^[99]提出了一种基于卷积神经网络的非结构化的三维点云法向估计方法，

可以用于曲面重建等。下图为网络结构示意图。该工作发表于 2019 年的 CVPR 会议中。Komarichev

等^[100]提出了环形卷积神经网络进行三维点云数据的处理，这种新的卷积算子可以很好捕捉点云的局部领域特征，在大规模场景的分割中取得较高精度。

此外还有诸多研究学者基于图神经网络（GNN，一般是使用图卷积网络，GCN）^[101]进行点云数据学习，也取得了不错的效果。

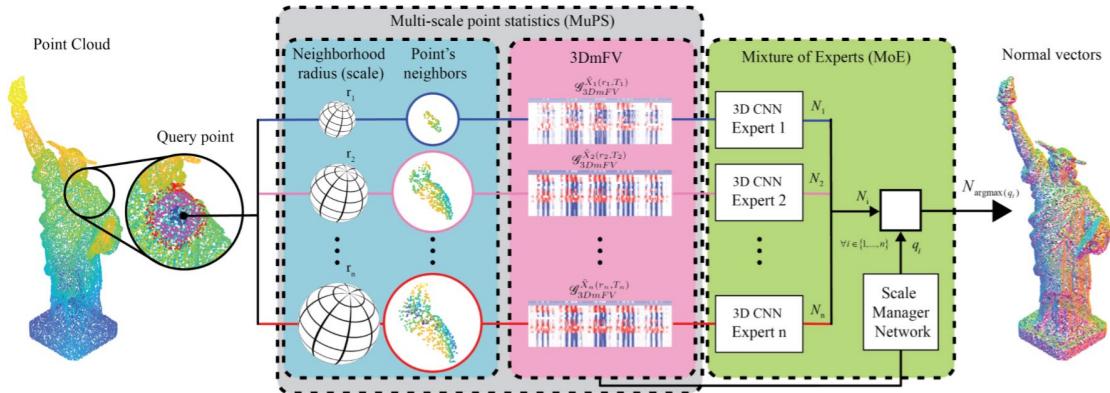


图 26 正态估计的 Nesti-Ne 结构

2.5 深度学习框架

目前，研究人员进行深度学习的研究和应用很少自己去写底层代码，更多的是基于深度学习框架。最早的深度学习框架是 Theano，该框架开发的目的是在 Python 中用作 CPU 和 GPU 的编译器，而不是一个深度学习框架。2017 年之后，Theano 停止了更新，淡出了人类的视野，但是其启发了后续框架的发展，具有奠基作用。

主流的深度学习框架包括加州大学伯克利分校博士贾扬清编写的 Caffe 和后续版本 Caffe2^[20]。

这也是比较早期的深度学习框架之一。贾扬清拥有清华大学的本科和硕士学位已经加州大学伯克利分校的博士学位。2019 年贾扬清博士回国，担任阿里巴巴技术副总裁。亚马逊集团研发的 Apache MXNet 框架^[21]。该框架由陈天奇和李沐团队开发完成，两人本科均毕业于上海交通大学。谷歌公司在 2015 年推出的 TensorFlow^[22]和 Keras 框架^[102]，以及后起之秀，Facebook 公司 2017 年发布的 PyTorch 框架^[23]，值得注意的是，贾扬清博士也是该框架主要研发人员。上述几种框架的对比如下表。

表 1 不同深度学习框架的比较

框架	核心编程语言	语言支持	开发单位
Caffe	C++	Python, Matlab	UCB
Caffe2			
Apache MXNet	C++, Cuda	Python, Scala, Julia, Clojure, Java, C++, R and Perl	Amazon
TensorFlow	Python, C++, Cuda	Python, C/C++, Java	Google
TensorFlow2.0			
Keras	Python	Python, Matlab	Google
PyTorch	C, Lua	Python, C/C++, Java, Lua	Facebook

目前在学术界，科研人员使用最多的是 PyTorch 框架。因为其编码思路清晰、简单，调试方便，API 合理，越来越受到人们的欢迎。而工业界使用 TensorFlow 框架更多一些，因为其部署比较方

便。但是我个人预测，在工业界也会有越来越多的人使用 PyTorch 框架。PyTorch 动态图机制比 TensorFlow 的静态图机制更加优越，TensorFlow 必须要建立一个会话 Session，才可以调用图，这给修

改和调试带来了极大的麻烦。虽然 Google 于 2019 年 10 月 1 日推出了 TensorFlow2.0，优化了 TensorFlow 的设计，风格上更加贴近 PyTorch。但是其与 TensorFlow1.x 的差异较大，两者 API 复杂，带来了额外的学习成本。显然，人们更愿意去学习和使用 PyTorch。

2.6 展望

深度学习在计算机视觉领域经过几年的发展，传统方向如目标检测和语义分割已经趋近于饱和，数据集的计算结果也已经达到极限，提高已经十分困难，需要更加细致和广泛的调试参数和优化结构，这往往需要很高的计算能力，对小型研究团队非常不友好。大的公司比如 Google 和 Facebook 等拥有数量众多的显卡，才可以撑得起大型网络和海量数据的计算。所以，我个人认为，对于小的研究团队，目前参与这个领域的研究并不是十分合适，建议更换一些方向。

笔者个人认为在现在和未来比较有提高潜力和应用价值的方向有：①细致分割，分割更加关注分割的精度和对边缘的细化程度。②关注小目标，以往的研究结果表明，大多数网络对大目标的检测和分割可以达到不错的效果，但是小目标的结果往

往不让人满意。同时小目标也是需要关注的。③三维数据处理，今年的 CVPR 的最佳论文和最佳学生论文均是对三维数据的研究，这势必也会推动在这方面的研究。④自动网络搜索(NAS)。让神经网络去搜索并优化网络结构，取代人工设计网络。第一篇自动搜索网络的论文诞生于 2016 年^[103]，此后该领域也得到了越来越多人的研究。

3 SHM 和 SDD 领域中一维数据处理

基于卷积神经网络的一维数据处理在土木工程领域中，主要是用于结构健康监测领域。在结构健康监测系统中，广泛布置有传感器，会实时采集时变信号。深度学习的作用就是分析采集的传感器时变信号，从中研判结构的健康状况、结构损伤评估、性能评估、结构自诊断等等。

传统的结构健康监测系统和基于深度学习的结构健康监测系统的对比如下图所示。与传统系统相比，基于深度学习的 SHM 系统避免了复杂的人工数据处理、数据特征筛选和提取过程和数据后处理分析过程，而是一步到位，自动实现数据的特征提出和分析，具有高度智能化，大大简化了人工操作，提高计算和分析效率。

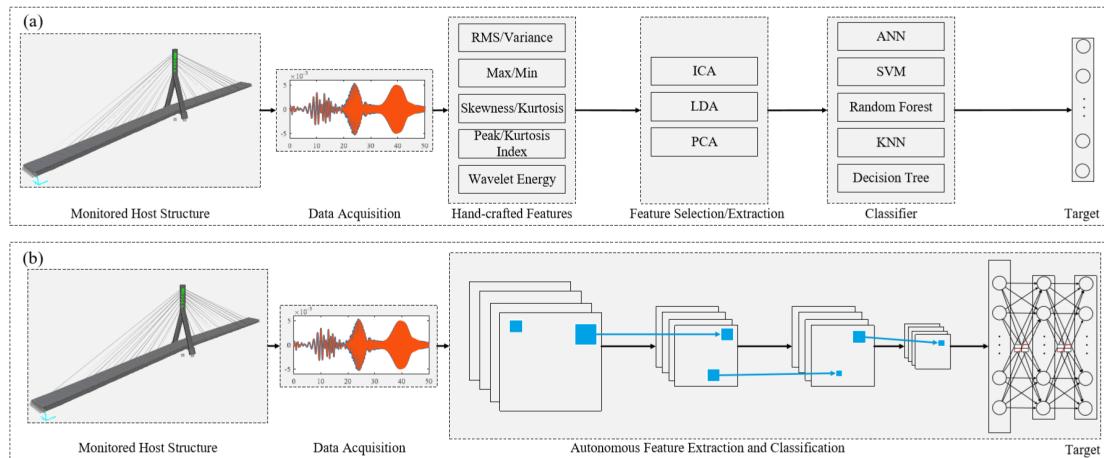


图 27 传统 SHM 和基于深度学习的 SHM 对比

3.1 结构响应预测

基于深度学习方法进行结构抗震工程领域的研究主要包括两大类，即①基于神经网络对结构响应进行预测和②对结构损伤进行定位与评估。Oh 等人^[104]提出一种基于卷积神经网络(CNN)的建筑结

构地震反应预测方法，卷积神经网络的输入数据为地震加速度时程，输出数据为预测的结构响应。下图为不同楼层中，神经网络模型预测的结构位移和试验结果的对比。从下图可以看出预测结果有比较高的精度。进一步的，Oh 等人^[105]将共振面积参数引入神经网络当中，提出了一种考虑地震动和结构

相关性的建筑物地震响应预测模型。提出的共振面积参数考虑了结构的固有频率和振型参与质量比等动力特性。与试验对比，神经网络预测结果达到了让人满意的预测精度。

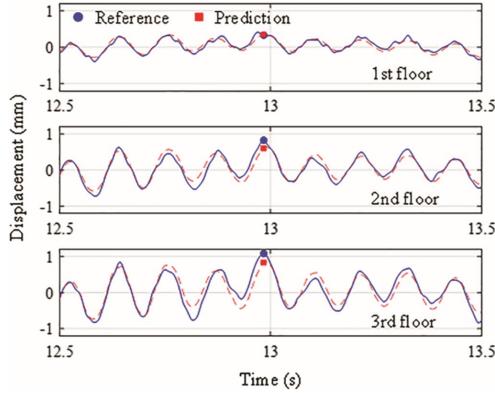


图 28 位移和预测结果

Zhang 等人^[106]使用深度长短期网络(LSTM)进行非线性结构地震响应预测。与传统的基于数值方法的非线性时程分析方法不同，他们提出的基于数

据驱动的深度学习模型能够准确预测建筑结构的弹性和非弹性响应。与 Oh 等人^[104]的方法类似，网络输入依然是地震加速度时程，输出是地震响应。进一步的，不再仅仅利用神经网络强大的非线性拟合功能，Zhang 等人^[107]将物理信息引入神经网络当中，提出了一种物理引导的卷积神经网络框架，在神经网络中引入物理约束，神经网络优化的一个目标使得下式趋于 0。

$$f: \ddot{\mathbf{y}}(t) + \mathbf{g}(t) = -\Gamma \ddot{\mathbf{y}}_g(t) \rightarrow 0 \quad (3)$$

所提的 PhyCNN 框架如下图所示。该框架借鉴了 PINNs^[88]的思路，取得了非常好的结构响应预测效果。最近，Zhang 等人将文献[106]和文献[107]的思路相结合，提出了一种基于物理信息的 Multi-LSTM 网络(PhyLSTM)^[108]。该网络借鉴了元学习的思路，从有限的数据中学习序列到序列特征，并将物理定律作为附加约束，编码到网络体系结构中，并嵌入整体损失函数中，使模型在可行解空间进行训练。模型具有较好的泛化能力和鲁棒性。

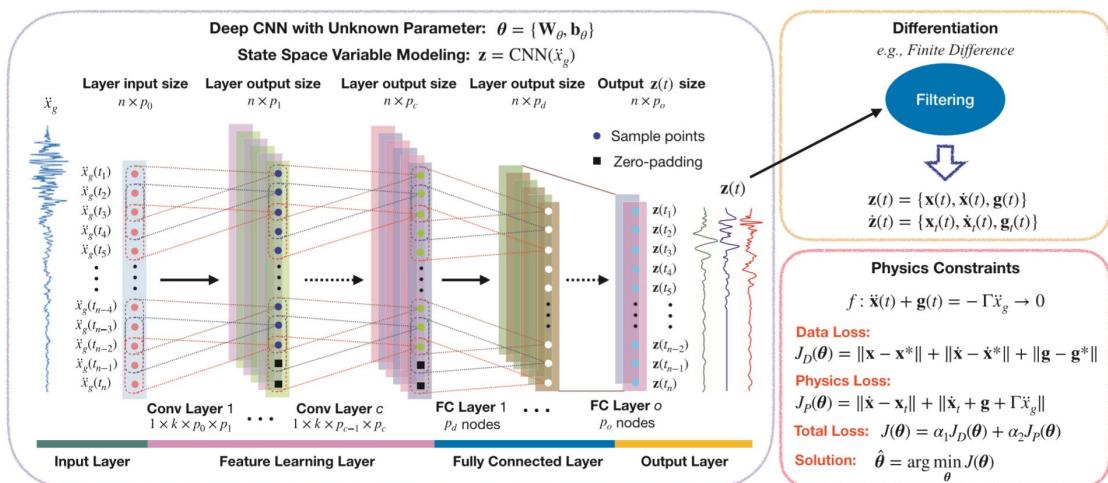


图 29 网络设计示意

不仅可以对结构在地震中的响应进行预测，Oh 等人^[109]基于卷积神经网络高层建筑的风振响应进行了估计。将结构的顶层位移和风速的时程实测数据作为神经网络的输入层，将构件的最大应变和最小应变作为神经网络的输出层，用来评判构件的安全性。Fan 等人^[110]基于 DenseNet 提出一种高层建筑响应重建方法，并将方法用于广州塔的风振响应预测中。结果显示，该方法在时域和频域都能准确地重建响应，具有较强的抗噪性。此外从重构的真实响应中识别出了高度一致的模态参数，方法的适

用性较好。提出的模型如下图 30 所示。

3.2 结构损伤识别

建筑的损伤与性能评估是深度学习在结构抗震或抗风等领域的另一个应用。Sajedi 等^[111]基于全卷积网络，提出一种地震中结构损伤定位和评估的神经网络模型。基于塑形旋转量划定性能级别，模型可以对结构的性能进行合理的评估。模型的结构如下图 31 所示。Sajedi 等^[112]还提出了一种基于数据驱动和累积强度的损伤特征识别损伤存在、可能

位置和严重程度的鲁棒框架。该框架考虑了地震危险性的不确定性和数据驱动方法中错误分类的不良后果，优化了基于混淆矩阵的目标函数。Wang 等^[113]提出一种用于土木工程结构健康监测的深残差网络框架，这些残差块作为特征提取器，附加全连接层用来识别损伤，结果显示该模型可以在存在测量噪声的情况下准确识别损伤。Ding 等^[114]提出了一种基于稀疏深度信念网络（DBN）的结构损

伤识别新方法。将结构的振动特征，即固有频率和振型作为网络的输入，网络的输出是结构的损伤位置和严重程度。Zhang 等^[115]使用一维 CNN 网络来识别结构在振动中质量和刚度局部微小变化的位置，具有很高的灵敏性。Azimi 等^[116]基于 CNN 从压缩后的结构响应数据（考虑了多种传感器）中，自动识别和定位结构的损伤。

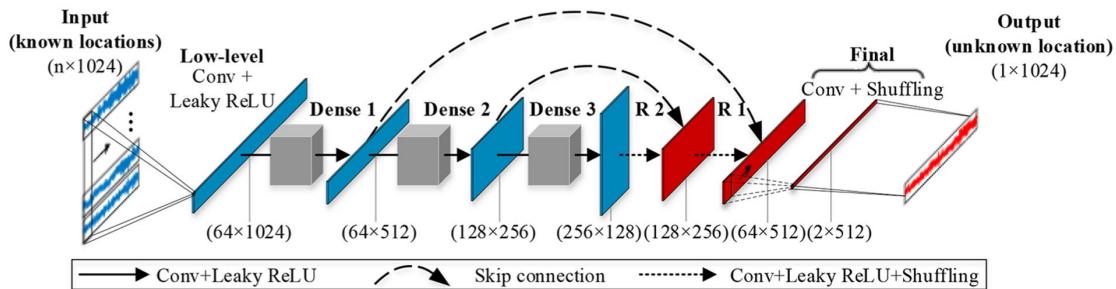


图 30 基于 DenseNet 的响应重构方法

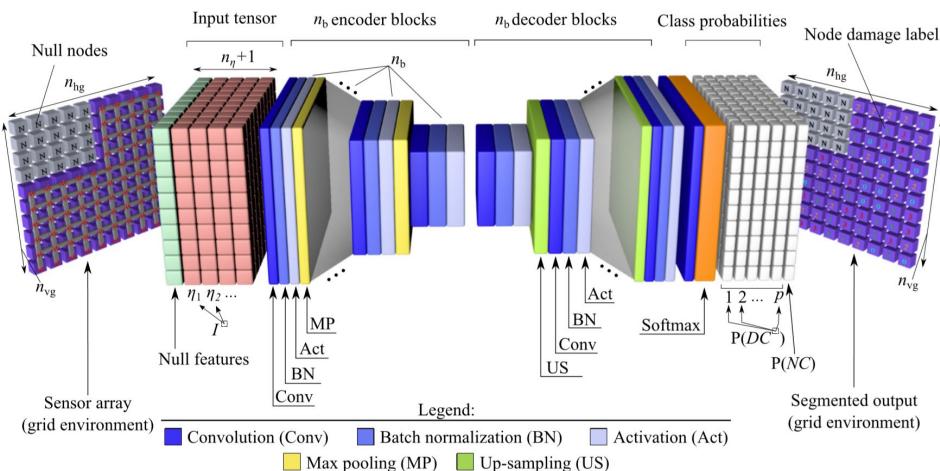


图 31 基于 CNN 的损伤识别和定位框架

3.3 其他应用

除了上面两个比较热门的研究方向之外，研究人员还对深度学习在一维数据处理的其他方面的应用进行了研究。振动数据中不可避免地存在测量噪声，这严重影响了被测振动信号用于结构识别和状态监测的可用性和质量。Fan 等人^[117]提出了一种基于特殊残差卷积神经网络（ResNet）的适用于恶劣和极端环境下的振动信号去噪方法。

利用无线传感器进行结构健康监测的信号传输损耗是一种常见的现象，这就降低了传感器监测结构状态的可靠性。高数据丢失率的实测振动数据

很难用于分析，这将导致结果的严重误差。Fan 等人^[118]提出了一种基于卷积神经网络的结构健康监测数据恢复方法，该方法在数据丢失率高达 90% 的情况下，仍具有良好的数据恢复能力。Tang 等人^[119]基于群体稀疏感知卷积神经网络提出了一种连续缺失的结构健康监测数据恢复方法。

SHM 系统往往会已经产生了大量的数据，但是这些数据的有效性和可利用性往往是个未知数。SHM 数据通常包括传感器故障或系统故障引起的多种类型的异常，这些异常可能干扰结构分析和评估。在常规的数据预处理中，需要多种信号处理技术分别检测异常，效率低下。Tang 等人^[120]基于卷

积神经网络（CNN）提出了一种数据异常自动检测方法，可以避免繁琐的人工筛查。

SHM 系统产生的大量数据也给数据存储带来了巨大的挑战，数据压缩与重构作为大型基础设施系统结构健康监测的一个新领域应运而生。Ni 等人

[121]提出了一种新的基于深度学习的数据压缩与重构框架，这种自编码结构能够在较低的压缩比（最低可以达到 10%）下高精度地恢复数据。所提的数据压缩和重建的深度学习模型如下图所示。

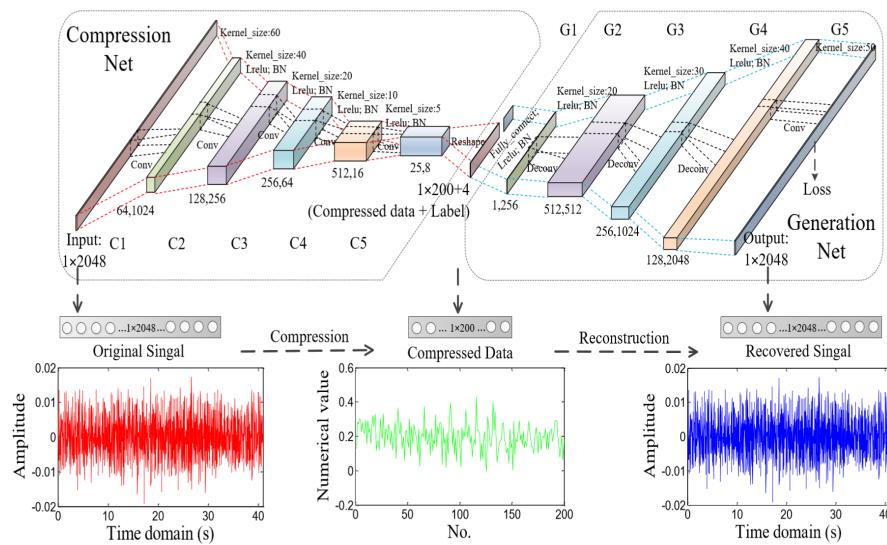


图 32 数据压缩和恢复网络框架

4 SHM 和 SDD 领域中二维数据处理

和深度学习在计算机视觉领域的发展类似，处理二维数据在土木工程领域也是应用最早和研究最为广泛的。在该领域的应用主要是对混凝土表面裂缝、道路裂缝、混凝土剥落、钢筋锈蚀等结构表观病害的自动检测和分割，其中对裂缝的自动检测和分割是研究最早并且相关的研究也是最多的。

4.1 裂缝检测与分割

近年来，仍在使用年限内的桥梁发生倒塌的事故屡见不鲜。桥梁结构的规律性健康监测和养护对于延迟桥梁使用寿命，保证桥梁安全性至关重要。裂缝是反映结构安全性、耐久性和可适用性的重要特征，也是桥梁安全检测中的重要一环。因此，周期性裂缝检测在既有混凝土结构的维护和运行中起着至关重要的作用。传统的裂缝检测主要是基于人工采集图像，通常需要借助手脚架、桥检车等重型设备。人工检测方式检测效率低下、成本较高并且主观性和不确定性较强。检验人员的技能水平和经验对裂纹检测的准确性有显著影响。而传统的数字图像处理算法，可以较好的处理一些简单的裂缝

图像，但是并不能够较好的适应复杂的工程环境，因此其使用受到限制[122-123]。为了提高裂缝评估的效率和客观性，弥补基于人的视觉检测方法的缺陷，人们在裂缝自动检测方面进行了广泛的研究。在深度学习方法兴起之前，主要是机器学习方法为主[124]。后来深度学习在多个计算机任务中取得了超越传统方法的结果，在土木工程裂缝检测领域的应用也得到了人们的关注。

2017 年，Cha 等人[125]在土木工程领域国际顶级期刊《Computer-Aided Civil and Infrastructure Engineering》（影响因子在土木工程领域排名第一）发表了第一篇使用深度学习来进行裂缝检测的论文，这也是深度学习方法在土木工程领域的首次应用。Cha 等人设计了一种卷积神经网络框架实现了裂缝的分块目标检测，截止到 2020 年 7 月 22 日，该篇论文的引用次已经达到了 581 次（ResearchGate 数据）。在土木工程领域，这是毫无疑问的具有巨大影响力和启发性的论文。同年，Lin 等人[126]设计了一个卷积神经网络用来学习特征和识别损伤位置，在无噪声和有噪声的数据集上都有很好的定位精度。之后，越来越多的研究人员开始了深度学习和土木工程交叉结合的研究。Yang 等人[127]基于全卷积网络 FCN 实现了像素级别的裂缝图像的语义分

割, 为裂缝长度和宽度的量化提供了基础。Ni 等人^[52]借鉴了 GoogleNet 的设计思路和特征融合的思想, 提出了一种新的基于图像的像素级结构损伤的检测与分割方法——CDN。该方法可以实现快速、高精度和自动的裂缝识别和分割。下图为所提裂缝识别和分割一体化网络框架。后续, 又提出了一种双尺度卷积神经网络, 用于进行裂缝宽度的定量测量,

基于 Zernike 矩算子可以将测量精度提高到亚像素级别^[53]。后续, 又 Liang^[128]则在多尺度卷积神经网络更进一步, 则提出了一种三层次的钢筋混凝土桥梁灾后检测方法。分别提出了图像分类、目标检测和语义分割的卷积神经网络进行系统级别的故障分类、构件级别的桥墩检测和局部损伤级别的损伤定位。

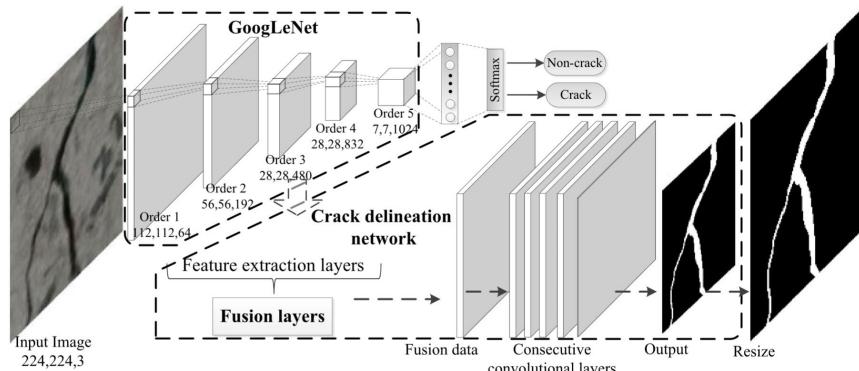


图 33 CDN 结构

最近两年, 不少研究人员在裂缝检测和分割的卷积神经网络上进行了创新, 不再盲目选择一些传统的卷积神经网络, 而是将不少新颖的神经网络和算法用于裂缝检测和分割领域。Zhang 等人^[129]提出了一种考虑局部交叉状态和交叉空间约束的上下文感知融合算法, 并将其与深层卷积神经网络相结合, 实现了任意尺寸图像的自动语义分割, 单张图片的平均处理时间为 0.7 秒。Mei 等人^[130]基于密集连接网络的裂缝自动分割方法, 并将其用到智能手机直接拍摄图像中, 体系方法具有较好的泛化能

力^[131]。下图为采用的 Dense block 的细节图。Choi 和 Cha^[132]提出了一种实时裂缝检测方法-SDDNet, 该模型由标准卷积、密集连接的可分离卷积模块、改进的 atrus 空间金字塔池模块和译码器模块组成。网络可以在 36 帧每秒的速度处理 1052×512 像素的图片, 比最近的工作快 46 倍。Kang 等人^[133]提出了一种 Faster R-CNN 的改进方案, 并结合修改的管状流场算法 (Tubularity Flow Field Algorithm, TUFF), 实现了像素级的复杂背景下的裂缝自动检测、分割和量化, 平均精度可以达到 95%。

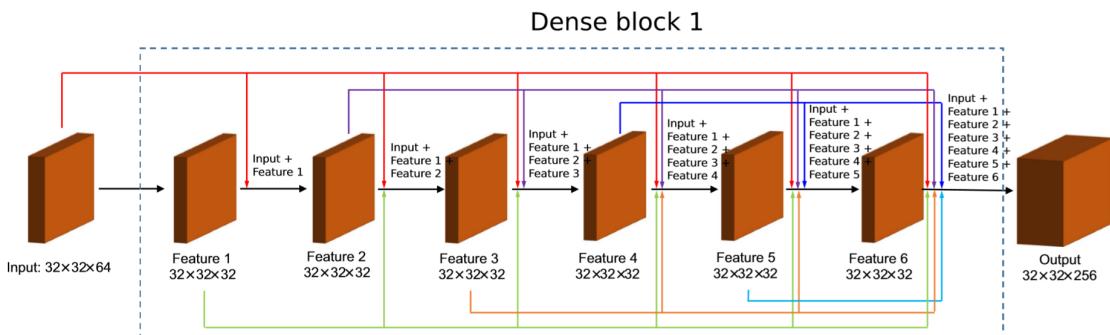


图 34 Dense block 细节

不仅建筑结构的表面会有裂缝产生, 路面裂缝和病害同样不可忽视。很多研究人员在路面裂缝自动检测领域进行了研究。Tong 等人^[134]比较早的使用卷积神经网络进行路面的病害检测。Maeda 等人^[135]使用卷积神经网络对智能手机直接拍摄的路面

图像进行了裂缝自动检测和分类, 拓宽了应用范围。还发布了一个道路病害数据集, 该数据集对推动道路病害的检测和分割起到一定的推动作用。Zhang 等人^[136]使用递归神经网络进行沥青路面像素级的裂缝分割。后续, Tong 等人^[137]提出了一种基于 FCN

网络和高斯条件随机场的路面裂缝自动分割方法，实现了路面裂缝的精细分割，具有较好的泛化能力。所提方法如下图所示。Mei 等人^[138]提出了一种基于车载摄像头和深度学习的路面裂缝检测的经济有效的解决方案，引入了生成对抗网络(Generative adversarial network, GAN)的思想，可以实现路面裂

缝的快速、实时分割。Maeda 等人^[139]也利用了 GAN 来进行病害检测，但是他们并没有直接进行检测，而是通过 GAN 生成了大量的路面病害照片作为训练数据，提高了路面病害检测精度。该方法本质是一个数据集的扩充。

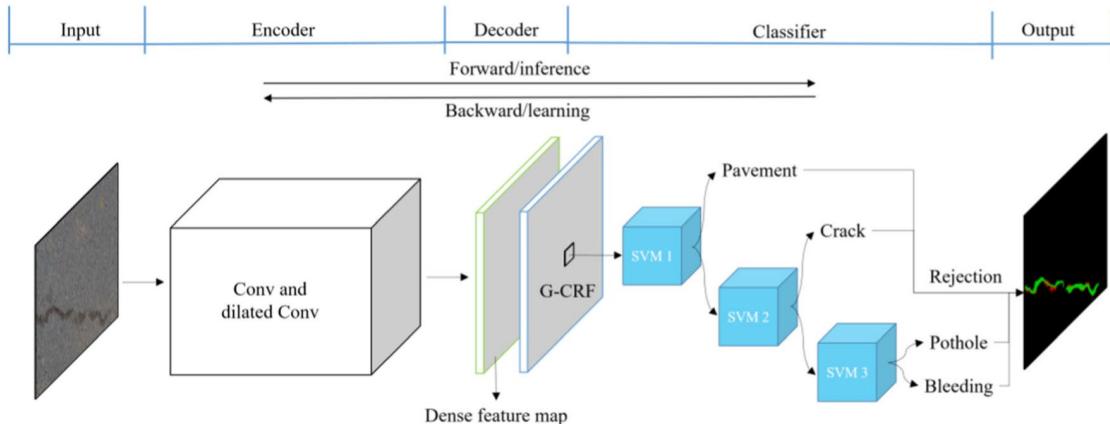


图 35 网络结构示意

4.2 混凝土结构其他病害

裂缝只是混凝土结构表观病害的一种，常见的病害还有混凝土剥落、孔洞、钢筋外露等，Li 等人^[140]提出了一种基于 FCN 的混凝土结构多损伤检测和病害分割方法，收集了 2750 张包含多种病害的图像进行训练和测试。结果显示所提方法的分割精度可以达到 91.59%。Xu 等人^[141]提出一种改进的 Faster R-CNN 网络，可以从图像中识别和定位受损钢筋混凝土柱的多类型地震后的损伤，包括混凝土开裂、混凝土剥落、钢筋外露和钢筋屈曲等。所提方法可以自动识别和定位多类型震害，平均精度可以超过 80%，部分震害的识别结果如下图所示。Zhang 等人^[142]基于 YOLOv3 网络，提出了一种混凝土桥梁损伤自动检测方法，可以实时检测裂缝、Pop-out、剥落和钢筋露出等四种病害。

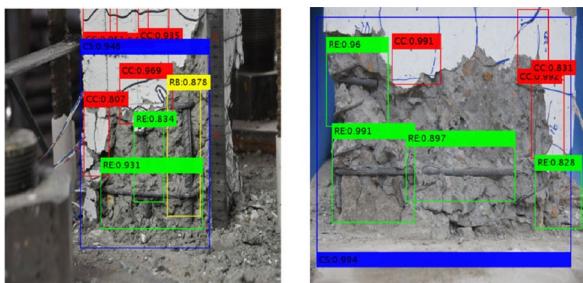


图 36 网络识别结果

4.3 钢结构病害检测

土木工程建筑中，按照材料来划分，最广泛使用的两种结构形式是混凝土结构建筑和钢结构建筑。此外，还有一些钢-混凝土组合结构。深度学习不仅在混凝土结构病害检测中得到了应用，其在钢结构领域的应用自然也得到了研究人员的关注。因此，也有研究学者将深度学习模型引入到钢结构检测当中。

钢结构的锈蚀是钢结构的主要病害之一。Ali 等人^[143]将深度学习方法引入了钢结构锈蚀检测当中。提出了一种基于深度学习和非致冷微测辐射热计（uncooled micro-bolometer）的钢构件红外图像自动检测方法。神经网络不直接对钢结构拍摄图像进行检测，而是对红外图像进行检测，这样可以获得更高的检测精度。Ali 等人提出的检测框架如下图

所示。

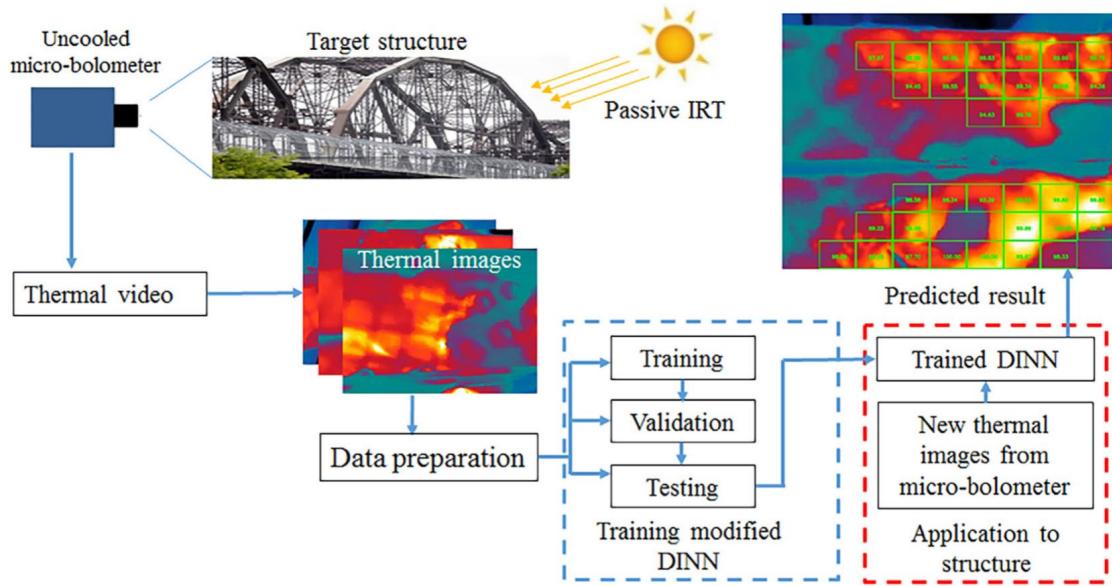
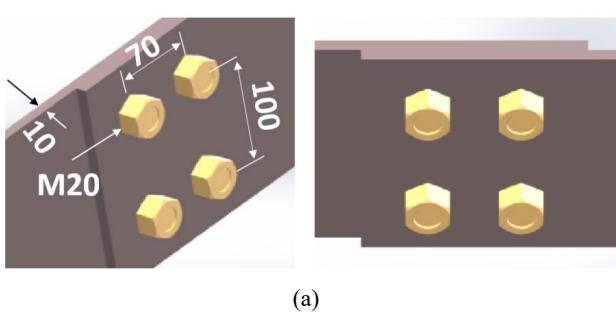


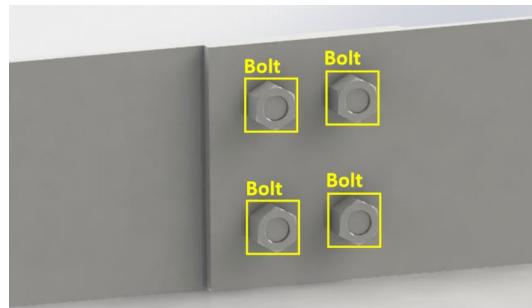
图 37 钢结构损伤检测流程图

还有研究学者对钢结构中广泛使用的连接构件螺栓的自动化检测问题进行了研究。螺栓作为钢结构的重要的组成部分，其损坏会影响到结构的安全和整体稳定，甚至引发严重的事故，因此在该领域的研究具有较重要的意义。Zhao 等人^[144]将深度学习方法与机器视觉相结合，提出一种螺栓松动角度的自动化检测技术，总体识别精度可以达到 0.914，并将模型移植到智能手机当中，实现了快速、简单的螺栓松动监测。

Pham 等人^[145]不直接基于螺栓真实图像，而是将深度学习和计算机图形学相结合，利用计算机合成的螺栓图像，来训练深度学习模型，进行螺栓的松动检测。然后通过一个实验室螺栓连接模型和实桥试验，验证了该框架的可行性。该方法利用合成数据进行神经网络的训练，可以减少收集高质量训练数据的时间和成本，具有较高的推广应用前景。基于计算机生成的三维模型和二维图形的螺栓检测如下图所示。



(a)



(b)

图 38 计算机生成模型：(a) 不同视角下的参数化图形模型，(b) 检测示意图

4.4 古建筑病害检测

历史釉面砖破损的检测与检测在历史建筑的维护与保护中起着重要的作用。然而，目前用于鉴定和评估历史建筑表面损伤的方法主要是人工目视检查的方法。传统方法耗时费力，且人工成本较高。迫切需要一种自动化和智能化的检测方法。

Wang 等人^[146]首次将深度学习方法引入古建筑的表观损伤检测中，相关成果发表在土木工程领域顶级期刊 CACAIE 上。作者们提出一种两阶段的检测方法，先定性检测后定量分析，具体检测流程如下图 39 所示。首先基于目标检测网络 Faster R-CNN 进行对琉璃瓦拍摄照片上的病害进行定性检测，然后基于语义分割网络 Mask R-CNN 进行病害的像素级分割，定量分析损伤特征。

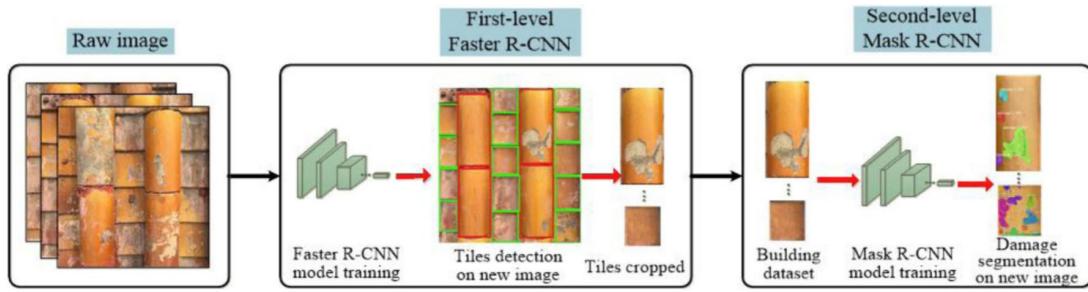


图 39 两阶段检测框架示意

4.5 智慧施工

土木工程领域的智慧建造与运维是土木工程未来发展的重要方向之一，其中智慧施工是关键一环。很多研究人员也将深度学习技术应用到施工当中，提高施工过程的智能化和自动化。Arabi 等人^[147]提出了一种改进的 MobileNet 模型，可以有效进行工程车辆的检测，验证了基于深度学习的建筑场景目标检测解决方案的实用性，可以用于智慧监测、

生产力评估和管理决策等。Shen 等人^[148]则提出了一种基于卷积神经网络的人脸检测和边界盒回归的安全帽佩戴检测方法。该方法基于 DenseNet 的深度迁移学习和互相蒸馏方法，可以有效检测出多尺度的小型安全帽，平均检测准确率达到了 94.47%。对工人安全帽佩戴情况进行检测是安全管理的重要一环，可以有效降低建筑业事故死亡率。这项研究具有很强的现实意义和推广应用潜质。模型的基本框架如下图 40 所示。

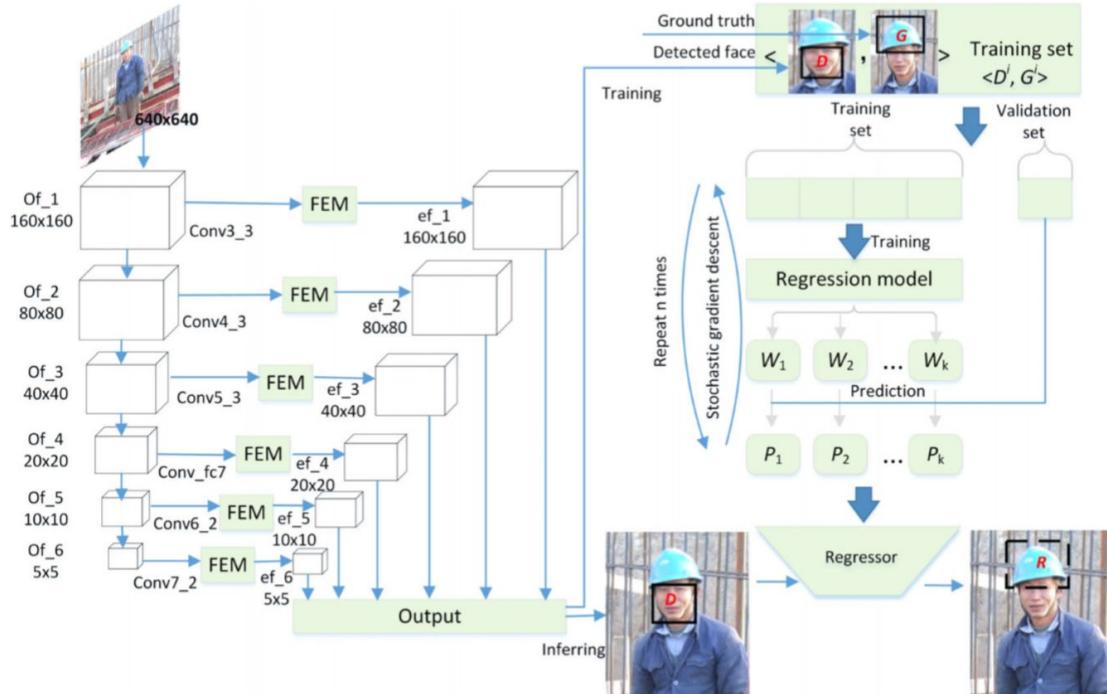


图 40 检测框架

4.6 其他应用

位移监测一直是结构健康监测的一个重要分支，多点位移监测不仅可以降低监测成本，而且可以提高监测效率。Zhang 等人^[149]提出了一种基于 FCN 和智能手机的多点位移监测方法。试验结果显示，在 2.5m 和 5m 处的标记监测误差均小于 1%，

在 7.5m 和 10m 处，误差分别为 1.696% 和 1.997%。方法可以满足实际工程需要，并且采用智能手机，成本得到了大大降低。

5 SHM 和 SDD 领域中三维数据处理

三维扫描设备和相关算法的发展推动了自动

驾驶和同步定位与建图（Simultaneous Localization and Mapping, SLAM）领域的发展。在土木工程领域，三维数据的应用研究也引起了很多学者的关注。笔者认为三维点云数据在土木工程领域有广阔的应用前景。人们可以通过三维扫描，建立建筑结构实际的三维模型从而可以与 BIM 技术（Building Information Model）和有限元技术相结合，转化为 BIM 模型和有限元模型，从而可以研究结构变形、评估健康状态和运维管理，这也就是经典的数字孪生的思想，具有广阔的应用前景。

更进一步的，可以扩大研究尺度，从单个建筑

推广至建筑群或整个城市。清华大学 Lu 等人^[150]提出了一个基于城市信息模型（City Information Model, CIM）的多灾害模拟框架，该框架考虑了地震、火灾和风三种灾害类型，由三个模块组成：① 数据转换；② 基于物理的危险分析和③ 高可信度可视化。同时，该框架也有三个显著的优势，具有较高的研究价值。① 多尺度模型的数据库能够满足利益相关者的各种需求；② 灾害分析都是基于物理模型的，模拟合理、科学；③ 高保真可视化可以帮助非专业用户更好地了解灾害场景。所提的城市信息模型多灾害模拟框架如下图所示。

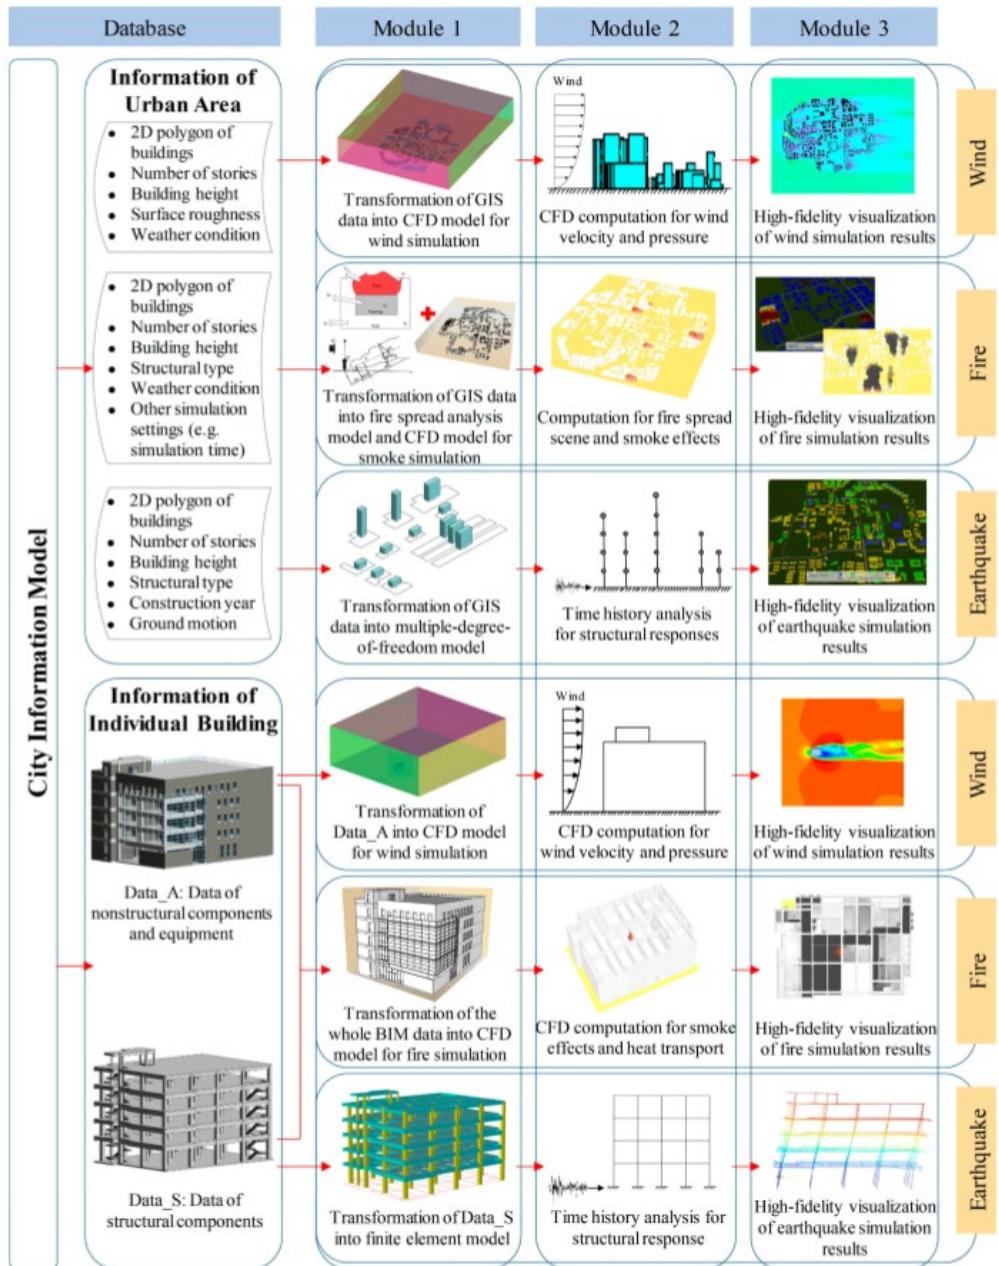


图 41 城市信息模型多灾害模拟框架

从上图可以看出，将实体模型转化为数字模型是最为关键的一步，目前的研究也主要集中在这个方向。Lu 等人^[151]基于聚类分析，提出一种从钢筋混凝土桥梁点云数据中识别桥墩、墩帽、梁和桥面板等构件的方法。Liu 等人^[152]，不基于点云数据，

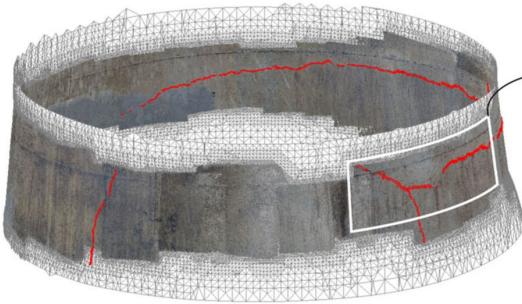


图 42 裂缝三维重建结果

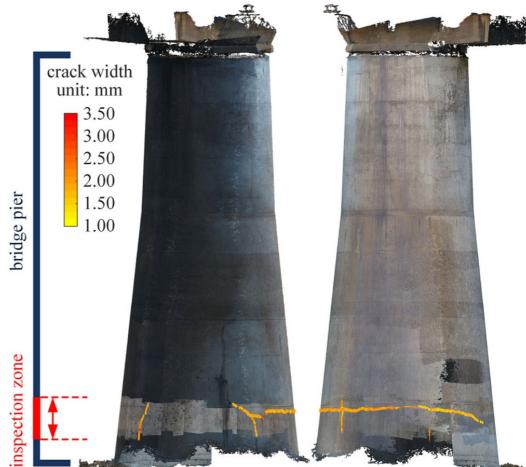


图 43 桥墩三维重建

上面两篇文章的工作都是基于传统的机器学习方法或者是计算机视觉方法，这些方法在简单物体、小尺度建筑的重建中可以取得较好的效果。但是实际建筑、桥梁等往往都非常复杂，存在很多局部特征区域，上述传统方法很难有比较好的效果。正如第 2 节介绍的，在计算机领域，基于深度学习的三维点云处理得到了广泛的关注，也取得了大量的研究成果，许多经典模型被提出。比如最初的 PointNet^[97]，更加关注局部特征的 PointNet++^[98]等等。在今年 CPRV2020 会议中，许多研究人员也提出了非常新颖的网络，比如基于三维 CNN 网络高性能三维目标检测框架 PV-RCNN^[153]，首先将模型体素编码到三维场景，然后进行基于 ROI 的特征提取，框架如下图 44 所示。

而是基于图像数据，提出了一种基于多视角图像的桥墩三维重建和桥墩裂缝检测方法。其裂缝三维重建效果如下图 42 所示，基于图像重建的桥墩三维模型如下图 43 所示。

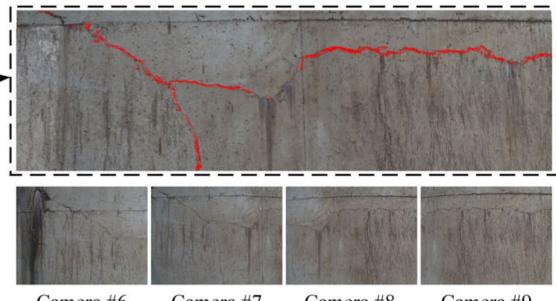


图 42 裂缝三维重建结果

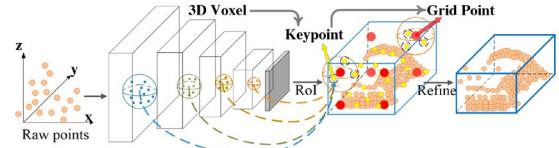


图 44 PV-RCNN 框架

Xu 等人^[154]则基于三维图卷积网络，提出了快速且可拓展的框架 Grid-GCN。Grid-GCN 采用了一种新的数据结构策略，覆盖感知网格查询（Coverage-Aware Grid Query, CAGQ）还采用了网格上下文聚合模块（Grid Context Aggregation, GCA）。CAGQ 可以提高空间覆盖率，同时降低了理论时间复杂度。Grid-GCN 在主要点云分类和分割基准点上实现了最先进的性能，运行速度比以前的研究快得多。Grid-GCN 在 ScanNet 上使用 81920 个点作为输入，其推理速度达到惊人的 50fps。网络思路如下图所示。

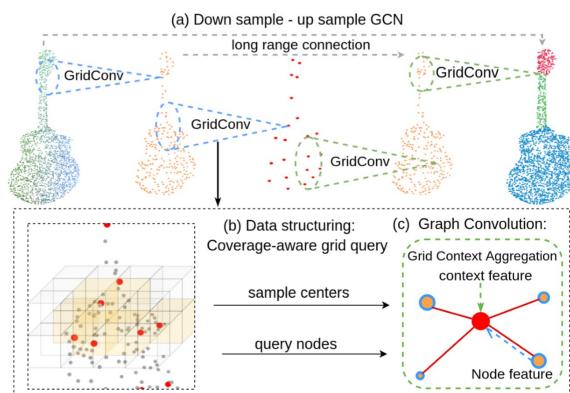


图 45 Grid-GCN 模型

但是目前基于深度学习方法进行建筑结构的三维点云目标检测和分割则应用较少，仅发现两个相关的工作，且都是在最近发表。说明这个领域还很新颖，亟待进一步发展。Kim 等人^[155]提出了一种利用深度学习的桥梁构件自动识别方法，该方法可

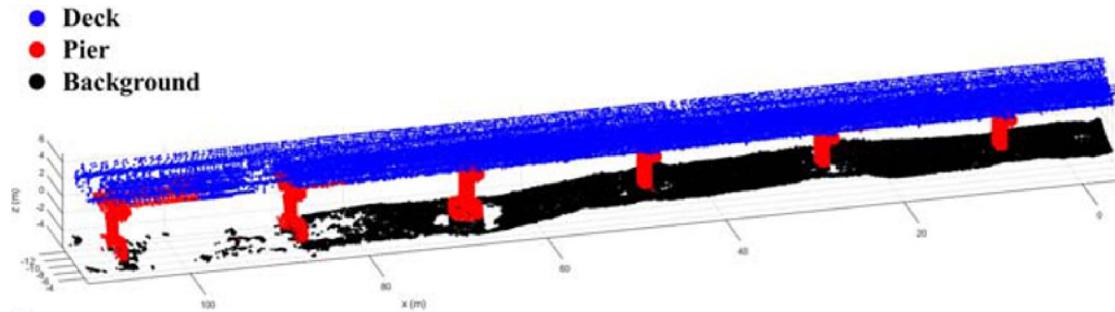


图 46 点云分割结果

上一个工作是进行较小跨度的混凝土梁式桥的三维重建。Hu 等人^[156]最近提出了一种基于深度学习和结构感知学习的大跨度斜拉桥三维重建方法，其结果对有噪声的数据和扫描不完整的情况下有较好的鲁棒性。并且该方法的精度与人工重建方法所得的结果是相似的，但是该方法运行速度更快，可以提高重建效率。这个方法也存在一定的局限性，仅仅具有比较好的重建效果，但是并没有进行构件的自动分割。这也是下一步的研究方向。方法流程如下图 47 所示。

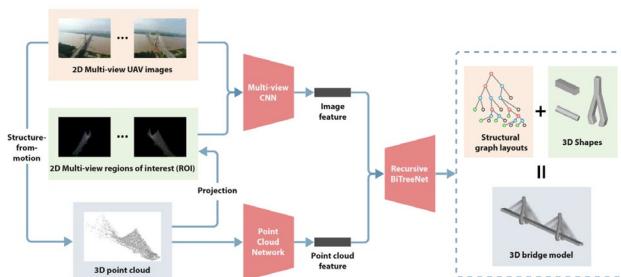


图 47 所提方法流程

以处理背景区域中有点的点云，大大减少了点云预处理的耗时。该方法识别结果如下图所示，可以看到对于形体差异较大的简单构件比如桥面和桥墩，可以有较高的分割精度。

6 智能检测设备

不仅人工智能算法在土木工程领域得到广泛关注，近年来，许多研究人员也开发了各式各样的智能检测设备对结构进行智能化、自动化检测，来取代传统的人工检测。Xue 等人^[157]和 Huang 等人^[158]开发了移动式的隧道检测图像采集设备（Moving Tunnel Inspection, MTI）进行自动的图像采集，然后基于 FCN 分割算法，实现了隧道衬砌缺陷的自动检测。该方法可用于地铁盾构隧道结构健康监测和维护中快速、准确地识别缺陷。下图为他们开发的隧道检测图像采集设备。Menendez 等人^[159]也开发了一种盾构隧道病害检测机器人，由移动车辆、起重机和高精度机械臂组成。与 Xue 和 Huang 等人的设备相比，这种机器人可以贴近结构表面拍照，可以得到更高质量的采集画面。但是这几种智能设备的问题都是只有图像采集的功能，并没有图像处理的功能，智能化有所欠缺。



图 48 移动式隧道检测图像采集设备

由于桥梁结构或房屋建筑往往尺寸较大，存在很多人工难以到达的地方。最近有很多研究学者将无人机用于基础设施病害检测。无人机操作便捷，轻巧易携带并且功能强大，看好其在土木工程领域的大规模应用。Metni 等人^[160]较早开始使用加装摄像头的无人机实现了桥梁裂缝的检测。Shang Jiang 和 Jian Zhang^[54]将无人机与爬壁机器人相结合，提出一种新颖的无人机系统，基于智能手机和深度学习模型实现了结构表面裂缝的实时检测。下图 49 为爬壁式无人机的三种模式，即正常飞行模式、墙壁贴近模式和屋顶贴近模式。与传统无人机相比，该型无人机贴近观察，可以发现更细微的病害。Tian 等人^[55]则基于无人机拍摄的视频信息实现了非接触式的索力实时测量。Wen Yi 和 Monty Sutrisna^[161]则使用无人机进行施工现场的监控，建立了一个最优的无人机调度模型，可以确保无人机在关键场地花费最多时间，同时总飞行时间最短，不会耗尽电池的电量。

此外，为了满足多样需求的检测任务，还有研究人员研发了各式各样的特种机器人。La 等人^[162]研制了用于钢桥检测的视觉摄像嵌入式车形磁爬机器人。Gibb 等人^[163]提出了一种由探地雷达、两个电阻率传感器和一个摄像系统组成的混凝土桥面检测机器人。Li 等人^[164]提出

了一种安装视觉摄像头的攀爬机器人，用于电缆检查。Jang 等人^[165]开发了由视觉摄像头、爬壁机器人和控制计算机组成的高耸桥墩的环形爬壁机器人系统，可以实现自动攀爬获得高质量的视觉图像以及裂缝的自动分割和量化，识别准确率可以达到 90.92%。图 50 为他们研发的攀爬机器人系统示意图。这套系统存在一个明显的问题是，只能适合在尺寸较固定的圆形桥墩上攀爬，尺寸过大或过小均不能满足较好的适应，对于截面非圆形的桥墩更是难以胜任。这也是下一步的改进方向。

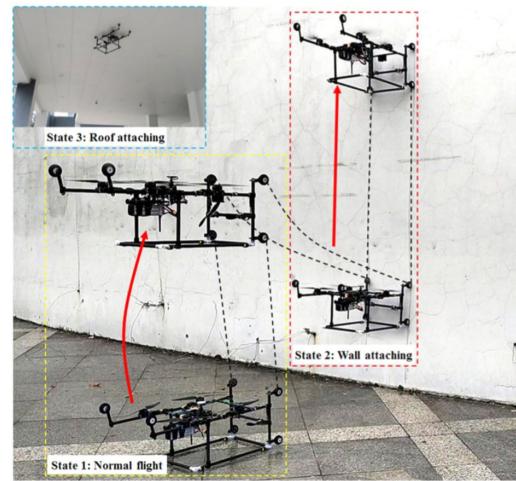


图 49 无人机系统三种模式

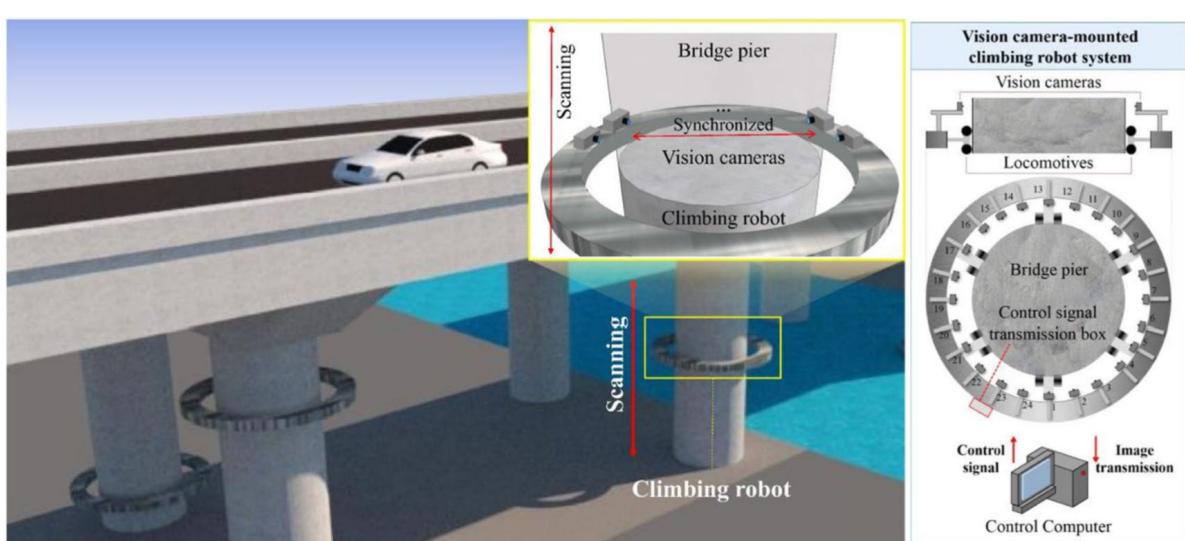


图 50 攀爬机器人系统示意图

自动化、智能化的检测设备将来必然会更加智能化，更加聪明，并取代人工检测。从而可以节省检测时间和检测成本。这也是智慧建造和运维的方向之一，也是土木工程未来发展方向之一，契合国

家“新基建”的发展要求，符合国家重大战略需求，希望可以早日出现自动化、智能化和适应复杂工程环境的设备出现，提高生产力，保障我国大体量基础设施的健康运行。

7 总结与展望

深度学习技术在解决土木工程健康监测和病害检测领域的优势显而易见，近年来的研究呈现指数级增长。本文综述了深度学习技术在健康监测和病害检测领域的应用及重要意义。从一维数据、二维数据、三维数据和智能检测设备等角度对目前的研究进行了归纳和总结。

(1) 在一维数据中的应用研究主要包括结构在地震或风等激励下的结构响应预测，建筑的损失定位和性能评估，以及结构健康监测信号的去噪、数据恢复、数据异常检测和数据压缩等等。

(2) 在二维数据中的应用主要包括，混凝土结构或路面的裂缝自动检测和分割、混凝土结构剥落、露筋等病害的自动检查、钢结构锈蚀检测和螺栓松动检测、古建筑损伤检测、智慧施工和位移监测。

(3) 在三维数据中的应用目前集中在对三维扫描数据进行结构重建和构件分割。Lu 等人^[150]提出了一个非常有前景的于城市信息模型的多灾害模拟框架，该框架非常具有发展潜力。

(4) 很多研究人员也进行了智能化检测设备的开发，包括隧道检测机器人、爬壁式无人机、环形爬壁机器人系统等等，并将机器人和智能检测算法相结合，实现了结构的自动检测。

与传统的人工检测方法相比，深度学习技术有诸多优势。(1) 避免健康监测信号复杂的数据前处理。深度学习可以自动完成数据的清洗和数据的分析，减少人工操作。(2) 可以和智能化设备相结合，实现病害的自动检测。降低检测盲区，减少检测的人力成本，提高检测效率和智能化水平。(3) 可以应用于建设工地，推动智慧建造，保障工人安全。

目前，在 SHM 和 SDD 的诸多领域，都有使用深度学习技术解决传统问题的论文发表。但是目前还存在一些有发展前景的研究空白或只有少量研究的方向。

在处理二维数据领域，存在一些非常有研究意义的关键科学问题，没有得到很好的解决。具体如下。

(1) 细微和模糊裂缝检测。将来的智能算法一定会和智能检测设备相结合。由于检测设备在运动，加之焦距和观测距离可能没有达到最优，拍摄的结果必然存在裂缝细微和模糊的问题。开发这类裂缝

的检测算法显得很有必要。这也涉及到计算机视觉中小目标分割这一个基本任务。

(2) 小样本和零样本学习

目前进行病害检测，往往需要人工标记大量的图片（通常为几千张），费时费力。并且在很多情况下，很难获得大量且高质量的数据。为此，如果能够在只有几十个样本或者没有样本的情况下，实现高质量的病害检测并且有较好的泛化能力，则会非常有意义。这也涉及到计算机视觉中小样本、零样本这一个基本任务，也涉及到无监督学习这个领域。目前，小样本的研究主要集中于图片分类领域，对于目标检测和语义分割由于难度较大，还没有很多研究涉及。这也是很有前景的方向。

(3) 基于深度学习的索力测量

目前，基于工业相机或者无人机的索力测量得到了许多研究人员的研究。但是对于拉索的提取很多依然基于传统的边缘检测方法。对于实际桥梁来说，拉索的背景有时候会非常复杂，那么此时传统的边缘检测方法是不再适用的，分割精度难以保证，这会导致很难在实际工程中应用，更多的是停留在实验室中。基于深度学习的边缘检测最近两年得到了关注，该方法比传统方法的分割精度更高，适用范围更广，具备实际工程应用的潜质。但是还未看到有文章将这种方法与索力测量相结合。我个人认为是非常有意义的方向。

(4) 水下病害检测

当前的研究主要是针对水上结构的病害检测。但是对于桥梁等结构来说，水下的桥墩、承台等结构的安全性同样值得关注。传统的检测方法是派潜水员下水探查，或者是基于声呐设备进行探究。这两种方法一是效率较低，二是派潜水员下水成本较高，安全性难以保证。目前亟需可以适合于水下病害检测的机器人和相关的智能检测算法。因为水会对光线发生折射，且水中有诸多杂质，所以水中拍摄的照片和空气中的有诸多差异，会存在雾化和变色的情况。所以针对水下照片的人工智能算法开发也显得十分关键。

在处理三维数据领域，我在去年就提出可以采用 3D-CNN 或者 GNN 来进行对建筑结构点云数据进行检测或者分割。那时候并没有相关论文发表。然后今年 5-6 月份，有两篇使用深度学习方法进行点云数据处理论文发表，即文献[155]和[156]。很遗憾我当时没有抓紧把想法付诸实践。

但是这两篇文献一个是对小尺度梁式桥进行构件分割、一个是对较大尺度斜拉桥进行重建。目前还没有基于深度学习技术对大尺度、复杂表面形状的桥梁或者建筑的三维点云进行自动分割和重建的方法出现。并且这两篇文献所使用的方法计算效率较低，需要相当高配置的计算机，很难有效的推广应用。所以对点云数据进行快速处理，也是一个非常好的方向。

此外，目前缺少获得三维模型后，讨论其 BIM 模型和有限元模型的论文。还没有从数字孪生的角度去思考的论文。这也是一个非常好的方向。

在智能设备领域，正如前面介绍的，目前已经有相当数量的智能检测设备问世。但是适合于桥梁底部的检测还未有合适的机器人问世。无人机在此区域飞行会产生 GPS 信号丢失，无法操控的问题。当前主流的方法依然是基于人工划船进行探查。但是如果桥下净空不足的情况，人工划船则很难进入。因此，迫切需要一款机器人可以有效进行桥下病害检测。还可以拓展至其他结构领域。比如包含有地下暗渠的结构，可能存在有毒有害气体，安排机器人进入就显得尤为必要。

当然以上几个方向是我在最近一段时间的阅读文献中发现并记录的，并未与专业人士进行探讨交流，只是作者本人的一些个人观点，实际的研究意义和价值还待商榷，仅供领域内相关科研人员参考。

本文旨在为本领域研究人员提供借鉴和相关参考资料，推动相关领域的进一步发展。

深度学习领域是少有的，热门新兴，同时中国人可以全程参与该领域从诞生、发展到成熟的全过程的领域。而其他领域，由于种种原因，中国学者的起步往往较慢，更多的是在其成熟期再加入，所以，一些做出开创性工作的学者，鲜有中国人的名字。就拿土木工程来说，结构动力学领域大师乔普拉、克拉夫；纤维增强水泥基复合材料（ECC）领域的开创者 Victor Li；在计算机辅助工程领域作出巨大贡献的 Hojjat Adeli 等等。

希望中国学者也能在深度学习与土木工程交叉领域做出更多原创性、颠覆性的成果。为学科发展和人类文明进步做出来自中国的贡献。有人将科学研究比喻为大树，一流学者为树干做拓展；二流学者树枝做跟踪；三流学者树叶做重复。希望我国可以涌现更多的一流学者！

参考文献：

- [1] A. L. Samuel. Some studies in machine learning using the game of checkers[J]. IBM Journal of Research and Development, 1959, 3(3): 535-554.
- [2] Q. Kong, D. T. Trugman, Z. E. Ross, et al. Machine learning in seismology: Turning data into insights[J]. Seismological Research Letters, 2018, 90(1): 3-14.
- [3] Y. Xie, M. E. Sichani, J. E. Padgett, et al. The promise of implementing machine learning in earthquake engineering: A state-of-the-art review[J]. Earthquake Spectra, Online Version of Record, 2020.
- [4] H. Adeli. Neural networks in civil engineering: 1989-2000[J]. Computer-Aided Civil and Infrastructure Engineering, 2001, 16(2): 126-142.
- [5] J. Zhang, T. Sato, S. Iai, et al. A pattern recognition technique for structural identification using observed vibration signals: Linear case studies[J]. Engineering Structures, 2008, 30: 1439-1446.
- [6] J. P. Amezquita-Sanchez, M. Valtierra-Rodriguez, M. Aldwaik, et al. Neurocomputing in civil infrastructure[J]. Scientia Iranica, 2016, 23(6): 2417-2428.
- [7] M.H. Rafiei, H. Adeli. A novel machine learning-based algorithm to detect damage in high-rise building structures[J]. The Structural Design of Tall and Special Buildings, 2017, 26 (18): e1400.
- [8] W. B. Chaabene, M. F. Moncef, L. Nehdi. Machine learning prediction of mechanical properties of concrete: Critical review[J]. Construction and Building Materials, 2020, 260: 119889.
- [9] K. Yan, H. Xu, G. Shen, et al. Prediction of splitting tensile strength from cylinder compressive strength of concrete by support vector machine[J]. Advances in Materials Science and Engineering, 2012, 21: 1937-1945.
- [10] J. Xu, X. Zhao, Y. Yu, et al. Parametric sensitivity analysis and modelling of mechanical properties of normal- and high-strength recycled aggregate concrete using grey theory, multiple nonlinear regression and artificial neural networks[J]. Construction and Building Materials, 2019, 211(30): 479-491.
- [11] M. Sonebi, A. Cevik, S. Grünwald, et al. Modelling the fresh properties of self-compacting concrete using support

- vector machine approach[J]. Construction and Building Materials, 2016, 106(1): 55-64.
- [12] D. V. Dao, H. B. Ly, S.H. Trinh, et al. Artificial intelligence approaches for prediction of compressive strength of geopolymers concrete[J]. Materials (Basel), 2019, 12(6):983.
- [13] O. B. Douma, B. Boukhadem, M. Ghrici, et al. Prediction of properties of self-compacting concrete containing fly ash using artificial neural network[J]. Neural Comput. Appl, 2017, 28: 707-718.,
- [14] S. Lee, C. Lee. Prediction of shear strength of FRP-reinforced concrete flexural members without stirrups using artificial neural networks[J]. Engineering Structures, 2014, 61: 99-112.
- [15] Y. LeCun, Y. Bengio, G. Hinton. Deep Learning[J]. Nature, 2015, 521: 436-444.
- [16] D. Michie, D. J. Spiegelhalter, C. C. Taylor, Machine learning, neural and statistical classification[M]. New York: Ellis Horwood, 1994
- [17] X. Yao. Evolving artificial neural networks[J]. Proceedings of the IEEE, 1999, 87(9): 1423-1447
- [18] D. Silver, A. Huang, C. Maddison, et al. Mastering the game of Go with deep neural networks and tree search[J]. Nature, 2016, 529: 484-489.
- [19] D. Silver, J. Schrittwieser, K. Simonyan, et al. Mastering the game of Go without human knowledge[J]. Nature, 2017, 550: 354-359.
- [20] Y. Jia, E. Shelhamer, J. Donahue, et al. Caffe: Convolutional architecture for fast feature embedding[C]// Proceedings of the 22nd ACM international conference on Multimedia. 2014: 675–678.
- [21] T. Chen, L. Mu, Y. Li, et al. MXNet: A Flexible and Efficient Machine Learning Library for Heterogeneous Distributed Systems[J]. arXiv preprint arXiv: 1512.01274, 2015
- [22] M. Abadi, P. Barham, J. Chen, et al. Tensorflow: A system for large-scale machine learning[C]// Proceedings of the OSDI. 2016: 265-283.
- [23] A. Paszke, S. Gross, F. Massa, et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library[J]. arXiv preprint arXiv: 1912.01703, 2019
- [24] B. Alipanahi, A. Delong, M. T. Weirauch, et al. Predicting the sequence specificity of DNA-and RNA-binding proteins by deep learning[J]. Nature biotechnology, 2015, 33: 831-838.
- [25] G. Ros, L. Sellart, J. Materzynska, et al. The SYNTHIA Dataset: A Large Collection of Synthetic Images for Semantic Segmentation of Urban Scenes[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 3234-3243.
- [26] D. George, E. A. Huerta. Deep Learning for real-time gravitational wave detection and parameter estimation: Results with Advanced LIGO data[J]. Physics Letters B, 2018, 778(10): 64-70.
- [27] K. T. Butler, D. W. Davies, H. Cartwright, et al. Machine learning for molecular and materials science[J]. Nature, vol. 559, pp. 547–555, 2018, doi: 10.1038/s41586-018-0337-2
- [28] O. Avci, O. Abdeljaber, S. Kiranyaz, et al. A Review of Vibration-Based Damage Detection in Civil Structures: From Traditional Methods to Machine Learning and Deep Learning Applications[J]. arXiv preprint arXiv: 1912.01703, 2004.
- [29] M. Azimi, A. D. Eslamlou, G. Pekcan, et al. Data-Driven Structural Health Monitoring and Damage Detection through Deep Learning: State-of-the-Art Review[J]. Sensors, 2020, 20(10): 2778-2811.
- [30] E. Cosenza, G. Manfredi. Damage indices and damage measures[J]. Progress in Structural Engineering and Materials. 2000, 2(1): 50-59.
- [31] D.M. Frangopol, J. P. Curley. Effects of damage and redundancy on structural reliability[J]. Journal of Structural Engineering, 1987, 468: 115109.
- [32] K. He, W. D. Zhu. Structural damage detection using changes in natural frequencies: Theory and applications[J]. Journal of Physics: Conference Series, 2011, 305(1):012054.
- [33] B. Kostic, M. Güll. Vibration-Based Damage Detection of Bridges under Varying Temperature Effects Using Time-Series Analysis and Artificial Neural Networks[J]. Journal of Bridge Engineering, 2017, 22(10): 04017065.
- [34] V. Meruane, W. Heylen. Structural damage assessment under varying temperature conditions[J]. Structural Health Monitoring, 2012, 11(3):345-357.
- [35] F. Seguel, V. Meruane. Damage assessment in a sandwich panel based on full-field vibration measurements[J].

- Journal of Sound and Vibration, 2018, 417:1-18.
- [36] Y.J. Cha, O. Buyukozturk. Structural damage detection using modal strain energy and hybrid multi-objective optimization[J]. Computer-Aided Civil and Infrastructure Engineering, 2015, 30(5): 347-358.
- [37] F. Magalhães, A. Cunha, E. Caetano, et al. Vibration based structural health monitoring of an arch bridge: From automated OMA to damage detection[J]. Mechanical Systems and Signal Processing, 2012, 28: 212-228.
- [38] J.P. Amezquita-Sanchez, H. Adeli. Signal Processing Techniques for Vibration-Based Health Monitoring of Smart Structures[J]. Archives of Computational Methods in Engineering, 2016, 23: 1-15.
- [39] A. Diez, N.L.D. Khoa, M. Makki Alamdari, et al. A clustering approach for structural health monitoring on bridges[J]. Journal of Civil Structural Health Monitoring, 2016, 6: 429-445.
- [40] O. Avci, O. Abdeljaber, S. Kiranyaz, et al. Wireless and Real-Time Structural Damage Detection: A Novel Decentralized Method for Wireless Sensor Networks[J]. Journal of Sound and Vibration, 2018, 424: 158-172.
- [41] A. K. S. Jardine, D. Lin, D. Banjevic, et al. A review on machinery diagnostics and prognostics implementing condition-based maintenance[J]. Mechanical Systems and Signal Processing, 2006, 20(7): 1483-1510.
- [42] M.S. Kan, A.C.C. Tan, J. Mathew, et al. A review on prognostic techniques for non-stationary and non-linear rotating systems[J]. Mechanical Systems and Signal Processing, 2015, 62: 1-20.
- [43] O. Abdeljaber, S. Sassi, O. Avci, et al. Fault Detection and Severity Identification of Ball Bearings by Online Condition Monitoring[J]. IEEE Transactions on Industrial Electronics, 2018, 66(10): 8136-8147.
- [44] R. Liu, B. Yang, E. Zio, et al. Artificial intelligence for fault diagnosis of rotating machinery: A review[J]. Mechanical Systems and Signal Processing, 2018, 108: 33-47.
- [45] R. Zhao, R. Yan, Z. Chen, et al. Deep learning and its applications to machine health monitoring[J]. Mechanical Systems and Signal Processing, 2019, 115: 213-237.
- [46] W. Zhang, C. Li, G. Peng, et al. A deep convolutional neural network with new training methods for bearing fault diagnosis under noisy environment and different working load[J]. Mechanical Systems and Signal Processing, 2018, 100: 439-453.
- [47] T. Ince, S. Kiranyaz, L. Eren, et al. Real-Time Motor Fault Detection by 1-D Convolutional Neural Networks[J]. IEEE Transactions on Industrial Electronics, 2016, 63(11): 7067-7075.
- [48] R. P. Bandara, T. H. T. Chan, D. P. Thambiratnam, et al. Frequency response function based damage identification using principal component analysis and pattern recognition technique[J]. Engineering Structures, 2014, 66(1): 116-128.
- [49] R. T. Wu, M. R. Jahanshahi. Data fusion approaches for structural health monitoring and system identification: Past, present, and future[J]. Structural Health Monitoring, 2018, 19(6): 147592.
- [50] R. Yao, S.N. Pakzad. Autoregressive statistical pattern recognition algorithms for damage detection in civil structures[J]. Mechanical Systems and Signal Processing, 2012, 31: 355-368.
- [51] S. Park, C.B. Yun, Y. Roh, et al. PZT-based active damage detection techniques for steel bridge components[J]. Smart Materials and Structures, 2006, 15(4): 957-966.
- [52] F. T. Ni, J. Zhang, Z. Chen. Pixel-level crack delineation in images with convolutional feature fusion[J]. Structural Control and Health Monitoring, 2019, 26(1): e2286
- [53] F. T. Ni, J. Zhang, Z. Chen. Zernike-moment measurement of thin-crack width in images enabled by dual-scale deep learning[J]. Computer-Aided Civil and Infrastructure Engineering, 2019, 34(5): 367-384.
- [54] S. Jiang, J. Zhang. Real-time crack assessment using deep neural networks with wall climbing unmanned aerial system[J]. Computer-Aided Civil and Infrastructure Engineering, 2020, 35(12): 549-564.
- [55] Y. D. Tian, C. Zhang, S. Jiang, et al. Noncontact Cable Force Measurement with Unmanned Aerial Vehicle and Computer Vision[J]. Computer-Aided Civil and Infrastructure Engineering, Online Version of Record, 2020.
- [56] W. J. Zhao, G. W. Zhang, J. Zhang. Cable force estimation of a long-span cable-stayed bridge with micro wave interferometric radar[J]. Computer-Aided Civil and Infrastructure Engineering, Online Version of Record, 2020.

- [57] V. Vapnik. Statistical Learning Theory. 1st ed[M]. New York: John Wiley & Sons, 1998.
- [58] C. M. Bishop. Pattern Recognition and Machine Learning (ed M. Jordan, J. Kleinberg and B. Scholkopf) [M]. New York: Springer, 2006.
- [59] K. P. Murphy. Machine Learning: A Probabilistic Perspective. Chance Encounters: Probability in Education[M]. Cambridge, MA; London: The MIT Press, 2012.
- [60] K. He, X. Zhang, S. Ren, et al. Deep Residual Learning for Image Recognition[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778.
- [61] A. Krizhevsky, I. Sutskever, G. E. Hinton, "Imagenet classification with deep convolutional neural networks[C]// Advances in Neural Information Processing Systems (NeurIPS). 2012: 1097-1105.
- [62] C. Szegedy, W. Liu, Y. Jia Y, et al. Going deeper with convolutions[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 1-9.
- [63] K. Simonyan, A. Zisserman. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [64] S. Xie, R. Girshick, P. Dollár, et al. Aggregated residual transformations for deep neural networks," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 1492-1500.
- [65] G. Huang, Z. Liu, L. V. Maaten, et al. Densely connected convolutional networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 4700-4708.
- [66] J. Hu, L. Shen, G. Sun, et al. Squeeze-and-excitation networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 7132-7141.
- [67] W. Sanghyun, P. Jongchan, J. Y. Lee, et al. CBAM: Convolutional Block Attention Module[J]. arXiv preprint arXiv: 1807.06521, 2018.
- [68] Z. Gao, J. Xie, Q. Wang, et al. Global Second-order Pooling Convolutional Networks[J]. arXiv preprint arXiv: 1811.12006, 2018.
- [69] I. Bello, B. Zoph, A. Vaswani, et al. Attention Augmented Convolutional Networks[J]. arXiv preprint arXiv: 1904.09925, 2019.
- [70] H. Zhang, C. Wu, Z. Zhang, et al. ResNeSt: Split-Attention Networks[J]. arXiv preprint arXiv: 2004.08955, 2020.
- [71] R. Girshick, J. Donahue, T. Darrell, et al. "Feature hierarchies for accurate object detection and semantic segmentation[C]// in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2014: 580-587.
- [72] R. Girshick. Fast R-CNN[C]// in Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2015: 1440-1448.
- [73] S. Ren, K. He, R. Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[C]// in Advances in Neural Information Processing Systems (NeurIPS). 2015: 91-99.
- [74] J. Redmon, S. Divvala, R. Girshick, et al. You only look once: Unified, real-time object detection[C]// in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 779-788.
- [75] W. Liu, D. Anguelov, D. Erhan, et al. SSD: Single shot multibox detector[C]// in European Conference on Computer Vision (ECCV), Springer, Cham. 2016: 21-37.
- [76] J. Redmon, A. Farhadi. YOLO9000: Better, Faster, Stronger[J]. arXiv preprint arXiv: 1612.08242, 2016.
- [77] J. Redmon, A. Farhadi. YOLOv3: An Incremental Improvement[J]. arXiv preprint arXiv: 1804.02767, 2018
- [78] A. Bochkovskiy, C. Y. Wang, H. Y. M. Liao, et al. YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. arXiv preprint arXiv: 2004.10934, 2020.
- [79] J. Long, E. Shelhamer, T. Darrell, et al. Fully convolutional networks for semantic segmentation[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 3431-3440.
- [80] O. Ronneberger, P. Fischer, T. Brox, et al. U-net: Convolutional networks for biomedical image segmentation[C]// Proceedings of Medical Image Computing and Computer-Assisted Intervention (MICCAI). 2015: 234-241.
- [81] K. He, G. Gkioxari, P. Dollár, et al. Mask R-CNN[C]// in Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 2961-2969.
- [82] M. X. Tan, R. M. Pang, Q. V. Le, et al. EfficientDet:

- Scalable and Efficient Object Detection[J]. arXiv preprint arXiv: 1911.09070, 2019.
- [83] M. X. Tan, Q. V. Le, et al. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks[J]. arXiv preprint arXiv: 1905.11946, 2019.
- [84] T. Qin, K. Wu, D. Xiu, et al. Data driven governing equations approximation using deep neural networks[J]. Journal of Computational Physics, 2019, 395: 620-635.
- [85] S. Pawar, S. M. Rahman, H. V addireddy, et al. A deep learning enabler for nonintrusive reduced order modeling of fluid flows[J]. Physics of Fluids, 2019, 31: 085101.
- [86] Z. Long, Y. Lu, X. Ma, et al. PDE-net: Learning PDEs from data[C]// in Proceedings of the 35th International Conference on Machine Learning (PMLR). 2018: 3208–3216.
- [87] Z. Long, Y. Lu, B. Dong, et al. PDE-Net 2.0: "Learning PDEs from data with a numeric-symbolic hybrid deep network[J]. Journal of Computational Physics, 2019, 399: 108925.
- [88] M. Raissi, P. Perdikaris, G. E. Karniadakis. Physics Informed Deep Learning (Part I): Data-driven Solutions of Nonlinear Partial Differential Equations[J]. arXiv preprint arXiv: 1711.10561, 2017.
- [89] M. Raissi, P. Perdikaris, G. E. Karniadakis. Physics Informed Deep Learning (Part II): Data-driven Discovery of Nonlinear Partial Differential Equations[J]. arXiv preprint arXiv: 1711.10566, 2017.
- [90] M. Raissi, G. E. Karniadakis. Hidden physics models: Machine learning of nonlinear partial differential equations[J]. Journal of Computational Physics, 2018, 357: 125-141.
- [91] M. Raissi, A. Yazdani, G. E. Karniadakis. Hidden fluid mechanics: Learning velocity and pressure fields from flow visualizations[J]. Science, 2020, 367: 1026-1030.
- [92] E. Haghigata, M. Raissib, A. Mourec, et al. A deep learning framework for solution and discovery in solid mechanics: linear elasticity[J]. arXiv preprint arXiv: 2003.02751, 2020.
- [93] M. T. Rad, A. Viardin, G.J. Schmitz, et al. -training deep neural networks for an alloy solidification benchmark problem[J]. Computational Materials Science, 2020, 180: 109687.
- [94] Y. J. Shin, J. Darbon, G. E. Karniadakis. Convergence and Generalisation of Physics Informed Neural Networks[J]. arXiv preprint arXiv: 2004.01806, 2020.
- [95] S. Z. Wu, C. Rupprecht, A. Vedaldi, et al. Unsupervised Learning of Probably Symmetric Deformable 3D Objects from Images in the Wild[J]. arXiv preprint arXiv: 1911.11130, 2019.
- [96] Z. Chen, A. Tagliasacchi, H. Zhang, et al. BSP-Net: Generating Compact Meshes via Binary Space Partitioning[J]. arXiv preprint arXiv: 1911.06971, 2019.
- [97] C. R. Qi, H. Su, K. Mo, et al. PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation[J]. arXiv preprint arXiv: 1612.00593, 2016.
- [98] C. R. Qi, L. Yi, H. Su, et al. LeonidasJ.Guibas, PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space[J]. arXiv preprint arXiv: 1706.02413, 2017.
- [99] Y. Ben-Shabat, M. Lindenbaum, A. Fischer, et al. NestNet: Normal Estimation for Unstructured 3D Point Clouds[J]. arXiv preprint arXiv: 1812.00709, 2018.
- [100] A. Komarichev, Z. Zhong, J. Hua, et al. A-CNN: Annularly Convolutional Neural Networks on Point Clouds[J]. arXiv preprint arXiv: 1904.08017, 2019.
- [101] Y. Wang, Y. Sun, Z. Liu, et al. Dynamic Graph CNN for Learning on Point Clouds[J]. arXiv preprint arXiv: 1801.07829, 2018, 468: 115109.
- [102] A. Mohan, S. Poobal. Crack detection using image processing: A critical review and analysis[J]. Alex. Eng. J. vol. 57, pp. 787–798, 2018, 468: 115109.
- [103] Elsken, Thomas, J. H. Metzen, F. Hutter. et al. Neural Architecture Search: A Survey[J]. Journal of Machine Learning Research, vol. 20, no. 55, pp. 1-21, 2019, 468: 115109.
- [104] B. K. Oh, Y. J. Park, H. S. Park, et al. Seismic response prediction method for building structures using convolutional neural network[J]. Structural Control and Health Monitoring, vol. 27, e2519, 2020, 468: 115109.
- [105] B. K. Oh, B. Glisica, S. Wook Park, et al. Neural network-based seismic response prediction model for building structures using artificial earthquakes[J]. Journal of Sound and Vibration, 2020, 468: 115109.
- [106] R. Zhang, Z. Chen, H. Sun. Deep long short-term memory networks for nonlinear structural seismic response prediction[J]. Computers and Structures, 2019, 220: 55-68,
- [107] R. Zhang, Y. Liu, H. Sun. Physics-guided convolutional

- neural network (PhyCNN) for data-driven seismic response modeling[J]. *Engineering Structures*, 2020, 215: 110704.
- [108] R. Zhang, Y. Liu, H. Sun. Physics-Informed Multi-LSTM Networks for Metamodeling of Nonlinear Structures[J]. arXiv preprint arXiv: 2002.10253, 2020.
- [109] B. K. Oh, B. Glisic, Y. Kim, et al. Convolutional neural network-based wind-induced response estimation model for tall buildings[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2019, 34: 843-858.
- [110] G. Fan, J. Li, H. Hao. Dynamic response reconstruction for structural health monitoring using densely connected convolutional networks[J]. *Structural Health Monitoring*, Online Version of Record, 2020.
- [111] S. O. Sajedi, X. Liang. Vibration-based semantic damage segmentation for large-scale structural health monitoring[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2020, 35: 579-596.
- [112] S. O. Sajedi, X. Liang. A datadriven framework for near real-time and robust damage diagnosis of building structures[J]. *Structural Control and Health Monitoring*, 2020, 27: e2488.
- [113] R. Wang, J. Li, H. Hao. Deep residual network framework for structural health monitoring[J]. *Structural Health Monitoring*, 2020, In press.
- [114] Z. Ding, J. Li, H. Hao. Structural damage identification by sparse deep belief network using uncertain and limited data[J]. *Structural Control and Health Monitoring*, 2020, 27: e2522.
- [115] Y. Zhang, Y. Miyamori, S. Mikami, et al. Vibration-based structural state identification by a 1-dimensional convolutional neural network[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2019, 34: 822-839,
- [116] M. Azimi, G. Pekcan. Structural health monitoring using extremely compressed data through deep learning[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2020, 35: 597-614.
- [117] Gao Fan, J. Li, H. Hao. Vibration signal denoising for structural health monitoring by residual convolutional neural networks[J]. *Measurement*, 2020, 157: 107651.
- [118] Gao Fan, J. Li, H. Hao. Lost data recovery for structural health monitoring based on convolutional neural networks[J]. *Structural Control and Health Monitoring*, 2019, 26: e2433.
- [119] Z. Tang, Y. Bao, H. Li, et al. Group sparsity-aware convolutional neural network for continuous missing data recovery of structural health monitoring[J]. *Structural Control and Health Monitoring*, Online Version of Record, 2020.
- [120] Z. Tang, Z. Chen, H. Li, et al. Convolutional neural network-based data anomaly detection method using multiple information for structural health monitoring[J]. *Structural Control and Health Monitoring*, 2019, 26: e2296.
- [121] F. T. Ni, J. Zhang, M. N. Noori. Deep learning for data anomaly detection and data compression of a long-span suspension bridge[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2020, 35(7): 685-700.
- [122] Y. Fujita, Y. Mitani, Y. Hamamoto, et al. A method for crack detection on a concrete structure[C]// Proceedings of International Conference on Pattern Recognition (ICPR). 2006: 901-904.
- [123] H. Oliveira, P. L. Correia. Automatic road crack segmentation using entropy and image dynamic thresholding[C]// Proceedings of European Signal Processing Conference (ESPC). 2009: 622-626.
- [124] T. Yamaguchi, S. Nakamura, R. Saegusa, S. Hashimoto, et al. Image-based crack detection for real concrete surfaces[J]. *IEEJ Transactions on Electrical and Electron Engineering*, 2008, 3(1): 128-135.
- [125] Y. J. Cha, W. Choi, O. Büyüköztürk. Deep learning-based crack damage detection using convolutional neural networks[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2017, 32(5): 361-378.
- [126] Y. Z. Lin, Z. H. Nie, H. W. Ma, et al. Structural damage detection with automatic feature-extraction through deep learning[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2017, 32(12): 1025-1046.
- [127] X. C. Yang, H. Li, Y. T. Yu, et al. Automatic Pixel-Level Crack Detection and Measurement Using Fully Convolutional Network[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2018, 33: 1090-1109.
- [128] X. Liang. Image-based post-disaster inspection of reinforced concrete bridge systems using deep learning with Bayesian optimization[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2019, 34: 415-430.
- [129] X. X. Zhang, D. Raian, B. Story, et al. Concrete crack

- detection using context-aware deep semantic segmentation network[J]. Computer-Aided Civil and Infrastructure Engineering, 2019, 34 (11): 8016-8025.
- [130] Q. P. Mei, M. Gul, M. R. Azim. Densely connected deep neural network considering connectivity of pixels for automatic crack detection[J]. Automation in Construction, 2020, 110: 103018.
- [131] Q. P. Mei, M. Güл. Multi-level feature fusion in densely connected deep-learning architecture and depth-first search for crack segmentation on images collected with smartphones[J]. Structural Control and Health Monitoring, Online Version of Record, 2020.
- [132] W. Choi, Y. J. Cha. SDDNet: Real-Time Crack Segmentation[J]. IEEE Transactions on Industrial Electronics, 2020, 67(9): 8016-8025.
- [133] D. Kanga, S. S. Benipala, Y. J. Cha, et al. Hybrid pixel-level concrete crack segmentation and quantification across complex backgrounds using deep learning[J]. Automation in Construction, 2020, 118: 103291
- [134] Z. Tong, J. Gao, A. Sha. Convolutional Neural Network for Asphalt Pavement Surface Texture Analysis[J]. Computer-Aided Civil and Infrastructure Engineering, 2018, 33: 1056-1072.
- [135] H. Maeda, Y. Sekimoto, and T. Seto, "Road Damage Detection and Classification Using Deep Neural Networks with Smartphone Images[J]. Computer-Aided Civil and Infrastructure Engineering, 2018, 33: 1127-1141.
- [136] A. Zhang, C. P. Wang, B. X. Li. Automated pixel-level pavement crack detection on 3D asphalt surfaces using a deep-learning network[J]. Computer-Aided Civil and Infrastructure Engineering, 2017, 32(10): 805-819.
- [137] Z. Tong, D. D. Yuan, J. Gao, et al. Pavement defect detection with fully convolutional network and an uncertainty framework[J]. Computer-Aided Civil and Infrastructure Engineering, Online Version of Record, 2020.
- [138] Q. P. Mei, M. Güл. A cost effective solution for pavement crack inspection using cameras and deep neural networks[J]. Construction and Building Materials, 2020, 256: 119397.
- [139] H. Maeda, T. Kashiyama, Y. Sekimoto, et al. Generative adversarial network for road damage detection[J]. Computer-Aided Civil and Infrastructure Engineering, Online Version of Record, 2020.
- [140] S. Y. Li, X. F. Zhao, G.Y. Zhou, et al. Automatic pixel-level multiple damage detection of concrete structure using fully convolutional network[J]. Computer-Aided Civil and Infrastructure Engineering, 2019, 34: 616-634.
- [141] Y. Xu, Y. Q. Bao, H. Li, et al. Automatic seismic damage identification of reinforced concrete columns from images by a region-based deep convolutional neural network[J]. Structural Control and Health Monitoring, 2019, 26: e2313.
- [142] C. Zhang, C. C. Chang, M. Jamshidi, et al. Concrete bridge surface damage detection using a single-stage detector[J]. Computer-Aided Civil and Infrastructure Engineering, 2020, 35: 389-409.
- [143] R. Ali, Y. J. Cha. Subsurface damage detection of a steel bridge using deep learning and uncooled microbolometer[J]. Construction and Building Materials, 2019, 226: 376-387.
- [144] X. F. Zhao, Y. Zhang, N. N. Wang, et al. Bolt loosening angle detection technology using deep learning[J]. Structural Control and Health Monitoring, 2019, 26: e2292.
- [145] H. C. Pham, Q. B. Ta, J. T. Kim, et al. Bolt-Loosening Monitoring Framework Using an Image-Based Deep Learning and Graphical Model[J]. Sensors, 2020, 20(12): 3382.
- [146] N. Wang, X. Zhao, Z. Zou, Autonomous damage segmentation and measurement of glazed tiles in historic buildings via deep learning[J]. Computer-Aided Civil and Infrastructure Engineering, 2020, 35: 277-291.
- [147] S. Arabi, A. Haghigat, A. Sharma, et al. A deep-learning-based computer vision solution for construction vehicle detection[J]. Computer-Aided Civil and Infrastructure Engineering, 2020, 35: 753-767.
- [148] J. Shen, X. Xiong, Y. Li, et al. Detecting safety helmet wearing on construction sites with bounding-box regression and deep transfer learning[J]. Computer-Aided Civil and Infrastructure Engineering, Online Version of Record, 2020.
- [149] Y. Zhang, X. Zhao P. Liu, et al. Multi-Point Displacement Monitoring Based on Full Convolutional Neural Network and Smartphone[J]. IEEE Access, 2019, 7: 139628-139634.
- [150] X. Z. Lu, D. L. Gu, Z. Xu, et al. CIM-Powered Multi-Hazard Simulation Framework Covering both Individual

- Buildings and Urban Areas[J]. Sustainability, 2020, 12(5059): 1-28.
- [151] R. Lu, I. Brilakis, C. R. Middleton. Detection of Structural Components in Point Clouds of Existing RC Bridges[J]. Computer-Aided Civil and Infrastructure Engineering, 2019, 34: 191-212.
- [152] Y. F. Liu, X. Nie, J. S. Fan, et al. Image-based crack assessment of bridge piers using unmanned aerial vehicles and three-dimensional scene reconstruction[J]. Computer-Aided Civil and Infrastructure Engineering, 2020, 35: 511-529.
- [153] S. Shi, C. Guo, L. Jiang, et al. PV-RCNN: Point-Voxel Feature Set Abstraction for 3D Object Detection[J]. arXiv preprint arXiv: 1912.13192, 2019.
- [154] Q. Xu, X. Sun, C. Y. Wu. Grid-GCN for Fast and Scalable Point Cloud Learning[J]. arXiv preprint arXiv: 1912.02984, 2019.
- [155] H. Kim, J. Yoon, S. H. Sim. Automated bridge component recognition from point clouds using deep learning[J]. Structural Control and Health Monitoring, 2020: e2591.
- [156] F. Hu, J. Zhao, H. Li, et al. Structure-aware 3D reconstruction for cable-stayed bridges: A learning-based method[J]. Computer-Aided Civil and Infrastructure Engineering, Online Version of Record, 2020.
- [157] Y. Xue, Y. Li. A fast detection method via region-based fully convolutional neural networks for shield tunnel lining defects[J]. Computer-Aided Civil and Infrastructure Engineering, 2018, 33(8): 638-654.
- [158] H. Huang, Q. Li, D. Zhang et al. Deep learning based image recognition for crack and leakage defects of metro shield tunnel[J]. Tunnelling and Underground Space Technology, 2018, 77: 166-176.
- [159] E. Menendez, J. G. Victores, R. Montero, et al. Tunnel structural inspection and assessment using an autonomous robotic system[J]. Automation in Construction, 2018, 87: 117-126.
- [160] N. Metni, T. Hamel. A UAV for bridge inspection: visual servoing control law with orientation limits[J]. Automation in Construction, 2007, 17(1): 3-10.
- [161] W. Yi, M. Sutrisna. Drone scheduling for construction site surveillance[J]. Computer-Aided Civil and Infrastructure Engineering, Online Version of Record, 2020.
- [162] H. M. La, N. Gucunski, K. Dana, et al. Development of an autonomous bridge deck inspection robotic system[J]. Journal of Field Robotics, 2017, 34(8): 1489-1504.
- [163] S. Gibb, H. M. La, T. Le, et al. Nondestructive evaluation sensor fusion with autonomous robotic system for civil infrastructure inspection[J]. Journal of Field Robotics, 2018, 35(6): 988-1004.
- [164] X. Li, C. Gao, Y. Guo, et al. Cable surface damage detection in cable-stayed bridges using optical techniques and image mosaicking[J]. Optics and Laser Technology, 2019, 110: 36-43.
- [165] K. Jang, Y. K. An, B. Kim, et al. Automated crack evaluation of a high-rise bridge pier using aring-type climbing robot[J]. Computer-Aided Civil and Infrastructure Engineering, Online Version of Record, 2020.